Portofolio Insinyur Data

Laporan Sertifikasi Kompetensi

Ardika Satria, S.Si., M.Si.

Program Studi Sains Data, Institut Teknologi Sumatera

Skema Insinyur Data (Data Engineer) · LSP Digital Kreatif Solusi

Draf 4 · 27 Oktober 2026 · Edisi untuk LSP DKS

Daftar Isi

Identitas Portofolio 3

1. Pendahuluan 4

2. Gambaran Proyek 8

3. Bukti per Langkah Kerja. 15

4. Hasil Kerja dan Pemecahan Masalah 29

5. Keterbatasan Bukti dan Tindak Lanjut 37

6. Lampiran 40

Identitas Portofolio

Asesi	Ardika Satria, S.Si., M.Si.
Jabatan	Dosen Program Studi Sains Data, Fakultas Sains, Institut Teknologi Sumatera (sejak 1 Maret 2023)
Organisasi yang dinilai	Kelompok Keahlian Program Studi Sains Data ITERA, pengelola Liga Lakehouse di Data Science Workbench
Standar	Keputusan Menteri Ketenagakerjaan Nomor 268 Tahun 2020 (SKKNI Bidang Data Management System, Sub Bidang Data Management) untuk sepuluh unit; SKKNI 103/2023 untuk unit J.62PDP00.011.1
Skema	Insinyur Data (Data Engineer), skema okupasi LSP Digital Kreatif Solusi (BNSP-LSP-2420-ID), sebelas unit
Proyek	gudang indikator SDG multisumber (20–21 Oktober 2026), pemakaiannya oleh graf pengetahuan, game, dan pemandu AI (21–23 Oktober 2026), serta evaluasi pengguna daring (sejak 23 Oktober 2026)
Repositori	portofolio publik `ardikasatria/sdgs-lakehouse`: bukti per langkah di `bukti/`, ringkasan hasil di `data/`, salinan kode gudang di `code/` (commit `dcaa55e` repositori penelitian Ardika); kode dan data asal di repositori penelitian Ardika (privat); layanan Data Science Workbench (privat)
Keadaan bukti	Gold acuan `657df68e…` (dibangun ulang di Mac, 21 Oktober 2026); paket level evaluasi `afbcbeef…`; layanan produksi per 24 Oktober 2026
Versi laporan	draf 4, edisi untuk LSP Digital Kreatif Solusi, 27 Oktober 2026

Laporan ini merangkum bukti dan menjelaskan alasan di balik setiap keputusan rancangan. Bukti rinci per elemen dan kriteria unjuk kerja (KUK) berada di folder `bukti/` repositori portofolio, satu folder untuk setiap langkah kerja, berurutan dari merencanakan sampai menjalankan. Bab 3 laporan ini mengikuti urutan folder itu, sehingga laporan dan bukti dapat dibaca berdampingan.

1. Pendahuluan

Bab ini menjelaskan persoalan yang melatarbelakangi pekerjaan, yaitu angka indikator SDG resmi yang berbeda antarsumber dan berubah antarrilis, lalu menempatkan pekerjaan pada standar dan skema yang menjadi acuan asesmen. Bagian akhir menjelaskan cara membaca bukti, tiga jenis bukti yang dipakai di seluruh laporan, dan batas penggunaan asisten AI selama pengerjaan.

1.1 Latar belakang pekerjaan

Indikator Tujuan Pembangunan Berkelanjutan (TPB/SDGs) untuk Indonesia diterbitkan oleh beberapa lembaga sekaligus. Satu indikator dapat muncul di Badan Pusat Statistik (BPS), di basis data SDG PBB, di World Development Indicators (WDI) Bank Dunia, di ILOSTAT atau WHO sebagai lembaga kustodian, dan untuk tujuan tertentu di kementerian sektoral seperti BNPB, KLH, dan KKP. Angka dari lembaga-lembaga tersebut tidak selalu sama, dan angka dari lembaga yang sama pun dapat berubah dari satu rilis ke rilis berikutnya. Pada penelitian kelompok keahlian sebelumnya, dua kanal milik BPS sendiri, yaitu WebAPI dan publikasi TPB, sudah berbeda pada 33 dari 1.435 sel yang beririsan.

Kondisi ini menjadi persoalan pengelolaan data. Sistem yang hanya menyimpan nilai terkini tidak dapat memanggil kembali angka yang benar pada hari terbitnya. Akibatnya, perbedaan antarsumber tidak dapat dijelaskan, dan pembelajar tidak dapat ditunjukkan dari rilis mana sebuah angka berasal. Contoh yang dipakai sepanjang pekerjaan adalah tingkat pengangguran terbuka (TPT) Agustus 2019. Angka tersebut tertulis 5,28 % pada Berita Resmi Statistik 5 November 2019, sedangkan tabel BPS saat ini menuliskan 5,23 % untuk kunci yang sama. Keduanya benar pada waktunya, dan sistem yang hanya menyimpan nilai terkini kehilangan yang pertama.

Berangkat dari persoalan tersebut, kelompok keahlian membangun gudang indikator SDG multisumber. Gudang ini menyimpan setiap rilis dari sebelas sumber statistik, merekonsiliasi perbedaan antarsumber dengan aturan yang ditetapkan sebelum data dibandingkan, lalu menerbitkan hasilnya sebagai data product per pilar TPB Bappenas dengan kontrak yang diuji. Pekerjaan berlangsung dalam tiga tahap.

1. **Tahap I, pembangunan gudang (20–21 Oktober 2026).** Tahap ini terdiri atas enam fase: tata kelola, data rujukan, akuisisi, Silver dan kualitas, gudang dan data mesh, serta graf pengetahuan dan korpus berita.
2. **Tahap II, pemakaian dan pengujian (21–23 Oktober 2026).** Gudang disambungkan ke graf pengetahuan TPB-KG, paket level Liga Lakehouse versi 4, pemandu AI Bravais, dan dasbor indikator, lalu diuji melalui lima pengujian: integrasi, graf, kompilasi paket, keterikatan jawaban Bravais, serta operasi dan keterulangan.
3. **Tahap III, evaluasi pengguna daring (23 Oktober–16 November 2026).** Paket produksi dipasang di server untuk Laga Liga Lakehouse, yaitu evaluasi pengguna yang dimainkan secara daring.

1.2 Tujuan laporan

Laporan ini disusun dengan tiga tujuan:

1. merangkum proyek sebagai satu rangkaian kerja dari sumber data sampai pemakai, sehingga dapat dibaca sebagai satu kesatuan;
2. memetakan hasil kerja ke sebelas unit skema Insinyur Data (Data Engineer) LSP Digital Kreatif Solusi, beserta berkas bukti dan angka yang dapat diperiksa ulang;
3. menyatakan secara terbuka bagian yang belum selesai, sehingga pekerjaan yang sudah dilakukan dapat dibedakan dari pekerjaan yang masih direncanakan.

Laporan ini tidak menambahkan hasil baru. Angka gudang diambil dari naskah teknis penelitian gudang, dan angka pemakaian dari laporan kelima pengujian Tahap II. Ringkasan JSON dan CSV yang menjadi dasar setiap angka disalin ke folder `data/` repositori portofolio; peta salinan ke asalnya ada di `data/asal.tsv`, dan sidik sha256 setiap berkas di `data/SIDIK.txt`. Setiap angka pada Bab 3 dan 4 dapat ditelusuri ke salah satu berkas itu.

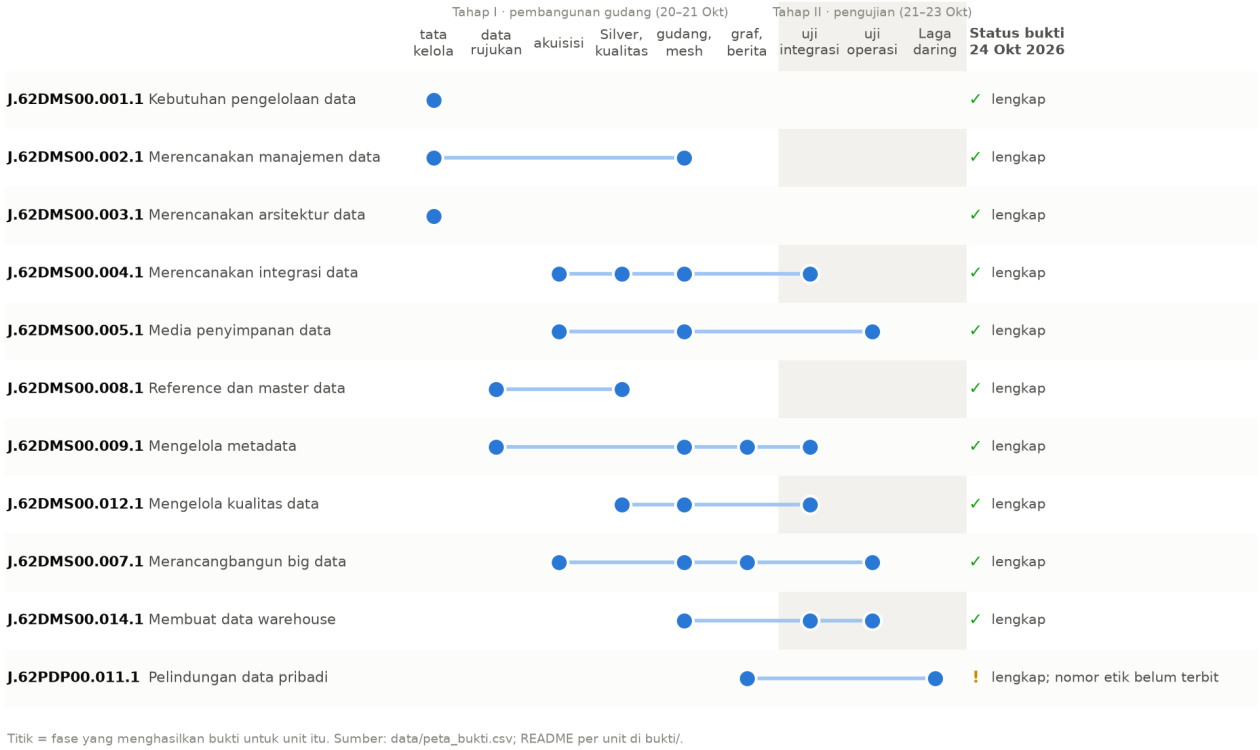
1.3 Standar dan skema

Standar yang digunakan adalah Keputusan Menteri Ketenagakerjaan Nomor 268 Tahun 2020 tentang Penetapan SKKNI Kategori Informasi dan Komunikasi Golongan Pokok Aktivitas Pemrograman, Konsultasi Komputer, dan Kegiatan YBDI Bidang Data Management System Sub Bidang Data Management, yang ditetapkan pada 26 Juni 2020. Standar ini memuat 22 unit berkode `J.62DMS00.0xx.1` dan mengadaptasi DAMA-DMBOK. Asesmen dilaksanakan di LSP Digital Kreatif Solusi (LSP DKS), LSP pihak ketiga berlisensi BNSP-LSP-2420-ID. Skema Insinyur Data (Data Engineer) di LSP DKS adalah skema okupasi yang memuat sepuluh unit dari SKKNI 268/2020 dan satu unit dari SKKNI 103/2023, yaitu J.62PDP00.011.1.

Tabel 1.1. Unit kompetensi skema Insinyur Data (Data Engineer) LSP DKS mengikuti urutan pada halaman skema, dan langkah kerja pada folder `bukti/` yang menjadi buktinya.

No	Kode unit	Judul unit	Standar	Langkah bukti
1	J.62DMS00.001.1	Mengidentifikasi Kebutuhan Pengelolaan Data untuk Proses Bisnis	SKKNI 268/2020	01 Kebutuhan data
2	J.62DMS00.002.1	Merencanakan Manajemen Data	SKKNI 268/2020	02 Rencana manajemen data
3	J.62DMS00.003.1	Merencanakan Arsitektur Data	SKKNI 268/2020	03 Arsitektur data
4	J.62DMS00.004.1	Merencanakan Integrasi Data	SKKNI 268/2020	07 Integrasi data
5	J.62DMS00.005.1	Merencanakan Media Penyimpanan Data	SKKNI 268/2020	06 Media penyimpanan
6	J.62DMS00.007.1	Merancangbangun Big Data	SKKNI 268/2020	10 Big data dan operasi
7	J.62DMS00.008.1	Mengelola Reference and Master Data	SKKNI 268/2020	04 Data rujukan dan master
8	J.62DMS00.009.1	Mengelola Metadata	SKKNI 268/2020	05 Metadata
9	J.62DMS00.012.1	Mengelola Kualitas Data	SKKNI 268/2020	08 Kualitas data
10	J.62DMS00.014.1	Membuat Data Warehouse	SKKNI 268/2020	09 Gudang data
11	J.62PDP00.011.1	Menerapkan Program Kerja Pelindungan Data Pribadi	SKKNI 103/2023	11 Pelindungan data pribadi

Bab 3 tidak mengikuti urutan nomor unit, melainkan urutan pekerjaan yang sebenarnya: merencanakan (langkah 01–03), menyiapkan acuan (04–05), membangun (06–09), lalu menjalankan (10–11). Urutan ini dipilih karena setiap langkah memakai hasil langkah sebelumnya, misalnya bukti big data memakai hasil gudang dan uji kualitas yang dijelaskan lebih dulu.



Gambar 1. Peta bukti: fase pekerjaan yang menghasilkan bukti untuk setiap unit dan status bukti per 24 Oktober 2026. Kesebelas unit berstatus lengkap; unit PDP membawa satu catatan terbuka tentang nomor persetujuan etik.

1.4 Cara membaca bukti

Setiap folder `bukti/<nomor>-<nama>/` berisi satu `README.md` yang menjawab empat hal: pertanyaan apa yang dijawab langkah itu, apa yang dikerjakan asesi dengan kata-kata sendiri, bukti per elemen unit beserta jenis dan statusnya, dan catatan terbuka tentang yang belum selesai. Di bawahnya, pemetaan rinci per KUK ditulis dengan rujukan ke berkas di `data/` dan `code/`. Aturan bukti mengikuti Pedoman BNSP 301-2013: valid (menjawab elemen yang dinilai), asli (pekerjaan asesi sendiri yang dapat dijelaskan tanpa membaca), terkini (menyebut tanggal jalan atau tanggal keputusan), dan memadai (setiap elemen punya sedikitnya satu bukti).

Bukti dikelompokkan menjadi tiga jenis, mengikuti pembagian bukti langsung, tidak langsung, dan tambahan pada asesmen portofolio.

- **L, bukti langsung: artefak yang berjalan.** Kode, konfigurasi, dan uji yang dapat dijalankan ulang dengan satu perintah `make`, misalnya `make m1-test` atau job Dagster `gudang_penuh`, serta layanan yang sedang berjalan di produksi. Salinan kode yang dirujuk ada di `code/`.
- **TL, bukti tidak langsung: keluaran terukur.** Manifest dan ringkasan hasil jalan, misalnya `m4_sidik_gold.json` untuk bukti rebuild dan `m3_kualitas.json` untuk ukuran kualitas, semuanya di `data/`.

- **T, bukti tambahan: dokumen tata kelola.** Piagam, matriks RACI, inventaris aset, analisis peraturan, surat izin, dan berkas etik.

Setiap langkah pada Bab 3 ditutup dengan status **lengkap** apabila setiap elemen sudah mempunyai bukti, disertai catatan terbuka bila ada bagian yang masih menunggu keputusan atau pihak luar. Hal yang belum dicocokkan dengan teks resmi atau masih menunggu keputusan penanggung jawab dinyatakan pada langkah yang bersangkutan dan dirangkum pada Bab 5.

1.5 Pernyataan penggunaan asisten AI

Gagasan proyek, pemilihan rancangan, dan setiap keputusan teknis berasal dari asesi. Dalam pengerjaannya, asisten AI (Claude) dipakai untuk membantu menulis kode dan dokumen serta untuk mengusulkan langkah teknis, yang kemudian diputuskan oleh asesi. Keputusan pokok, seperti model operasional federasi, aturan rekonsiliasi, kelas tayang menurut lisensi, skema bitemporal, keputusan tidak memakai Spark, dan perbaikan setiap insiden, tercatat bertanggal pada dokumen rencana kerja dan catatan rencana uji di repositori penelitian. Lampiran 6.1 merangkum keputusan-keputusan tersebut beserta alternatif yang dipertimbangkan dan alasannya. Asesi bertanggung jawab penuh atas isi laporan ini dan harus dapat menjelaskan setiap keputusan di dalamnya tanpa membaca dokumen.

2. Gambaran Proyek

Gudang indikator SDG multisumber menyimpan 2.662 rilis dari sebelas sumber statistik, memetakannya ke kode kanonik, merekonsiliasi perbedaan antarsumber, dan menerbitkan sembilan data product berkontrak yang dipakai oleh graf pengetahuan, paket level Liga Lakehouse, pemandu AI Bravais, dan dasbor. Bab ini menjelaskan organisasi, sumber data, arsitektur, stack teknologi, model data mesh, pemakaian hasil, serta keadaan pekerjaan pada 27 Oktober 2026.

2.1 Organisasi dan proses bisnis

Organisasi yang dinilai adalah Kelompok Keahlian Program Studi Sains Data ITERA sebagai pengelola Liga Lakehouse, yaitu game edukasi indikator SDG yang berjalan di Data Science Workbench (DSW, `sd.itera.ac.id`), beserta lakehouse riset yang memasoknya. Kelompok keahlian menjalankan tiga fungsi yang memakai data: penelitian rekonsiliasi statistik resmi multisumber, layanan pembelajaran melalui Liga Lakehouse dan pemandu AI Bravais, serta pengajaran pada mata kuliah Pergudangan Data dan Data Wrangling. Proses bisnis pokoknya dimulai dari mengunduh rilis resmi, kemudian merekonsiliasi dan menyimpan setiap rilis, mengompilasi paket level, menyajikannya kepada pemain, dan akhirnya mengevaluasi kegunaannya.

Seluruh pekerjaan diikat oleh satu prinsip tata kelola: setiap angka indikator SDG resmi Indonesia yang pernah terbit harus dapat dipanggil ulang, ditelusuri sampai rilisnya, dan dijelaskan kepada pembelajar.

2.2 Sumber data

Pada fase akuisisi, data diambil dari sebelas sumber statistik dan tiga sumber berita. Setiap payload ditulis apa adanya ke lapis Raw dengan manifest sha256, lalu setiap rilis didaftarkan ke registri `dim_rilis` beserta jenis bukti tanggal rilisnya.

Tabel 2.1. Sumber gudang (`data/gudang/volume.json`, registri rilis). Kelas tayang mengikuti keadaan saat pengujian Tahap II; sejak keputusan 22 Oktober 2026 semua sumber statistik masuk kelas A.

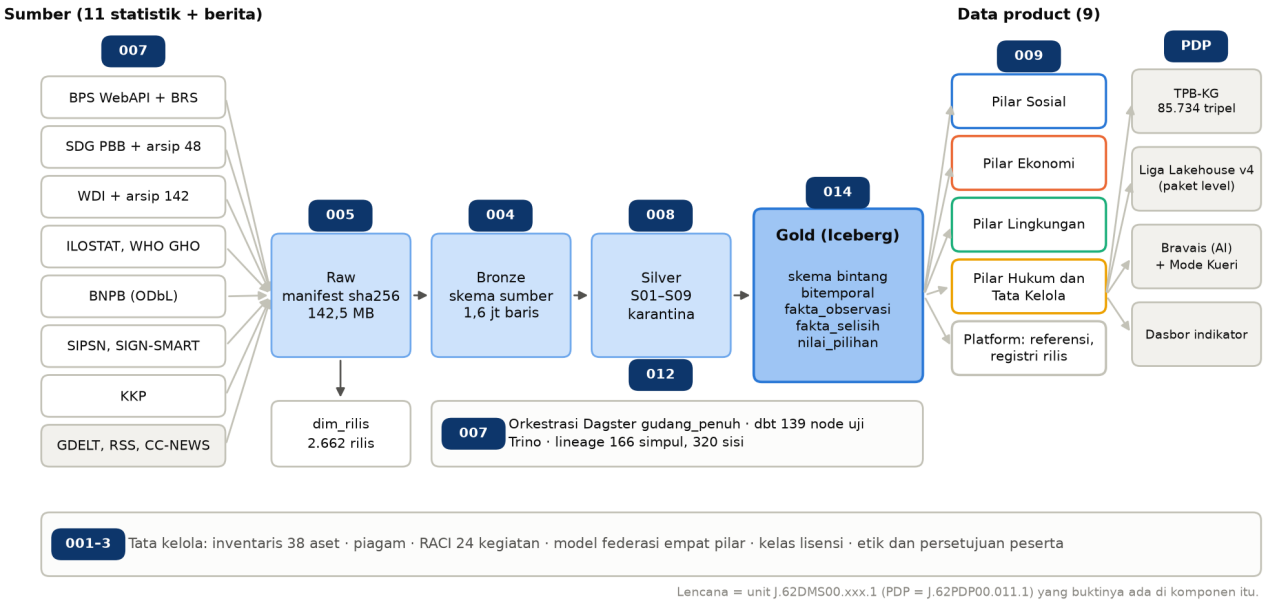
Sumber	Tujuan SDG	Tingkat	Rilis	Bukti tanggal rilis	Kelas tayang
BPS WebAPI	1–11, 15–17	provinsi, nasional	73	pembaruan sumber, rilis resmi	A
BPS Berita Resmi Statistik	indikator yang dirilis lewat BRS	nasional	2.143	rilis resmi	A
Basis data SDG PBB (API dan arsip 48 rilis)	1–17	nasional	49	rilis resmi	B
WDI (API dan arsip 142 versi)	banyak tujuan	nasional	143	rilis resmi, pembaruan sumber	A
ILOSTAT	1, 5, 8, 10	nasional	26	pembaruan sumber	A
WHO GHO	2, 3, 6	nasional	42	pembaruan sumber	A
BNPB	13 (juga 1.5, 11.5)	provinsi, kab/kota	113	pembaruan sumber	A-SA (ODbL)
SIPSN KLH	12	kab/kota	2	tanggal unduh	B
SIGN-SMART KLH	13	provinsi	28	tanggal unduh	B

Sumber	Tujuan SDG	Tingkat	Rilis	Bukti tanggal rilis	Kelas tayang
KKP	14	provinsi, nasional	43	tanggal unduh	B
GDELT, RSS, CC-NEWS	klaim berita	–	16	tanggal unduh	C (tidak tayang)

Secara keseluruhan tercatat 2.662 rilis data statistik, Raw sebesar 142,5 MB dalam 889 berkas, dan Bronze sebesar 32,7 MB atau 1.607.907 baris. Kelas tayang ditentukan oleh lisensi. Kelas A bersifat terbuka, kelas A-SA wajib berlisensi sama, kelas B hanya dipakai untuk rekonsiliasi sampai statusnya jelas, dan kelas C tidak pernah ditayangkan. Pada 22 Oktober 2026 diputuskan bahwa basis data SDG PBB, SIPSN, SIGN-SMART, dan KKP diperlakukan sebagai data publik dengan atribusi wajib, sehingga keempatnya masuk kelas A untuk paket Laga. Perubahan tersebut hanya menyentuh seed lisensi. Gudang kemudian dibangun ulang dari awal dengan sidik baru `1b8c95e3…`, sedangkan angka pada laporan ini tetap mengacu pada Gold `657df68e…`.

2.3 Arsitektur

Gudang disusun sebagai lakehouse berlapis (medallion) (Raw, Bronze, Silver, Gold) dengan skema bintang bitemporal di lapis Gold dan data product per pilar TPB di atasnya. Gambar 2 menandai setiap komponen dengan unit kompetensi yang buktinya berada pada komponen tersebut.



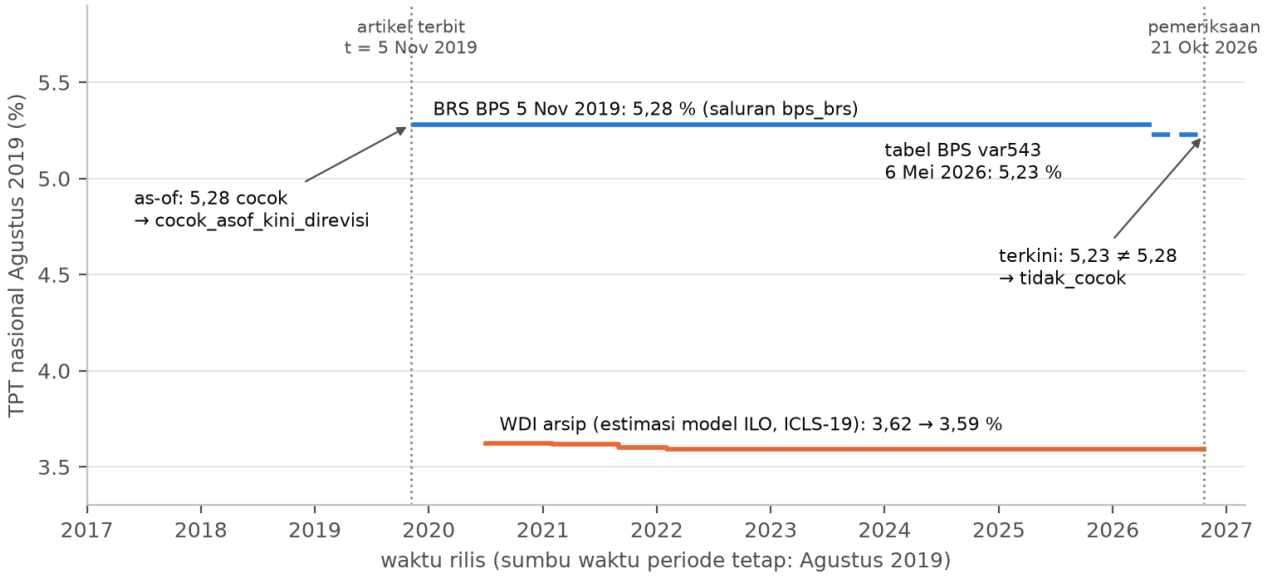
Gambar 2. Arsitektur dari sumber sampai pemakai, bertanda unit kompetensi. Lencana biru tua menunjuk unit J.62DMS00.xxx.1 yang buktinya berada pada komponen tersebut; PDP adalah J.62PDP00.011.1.

Tabel 2.2. Aturan per lapis.

Lapis	Isi	Aturan
Raw	payload asli per sumber per unduhan	hanya bertambah, tidak pernah ditimpa; manifest sha256
Bronze	payload diurai menjadi baris apa adanya	dapat dibangun ulang tanpa jaringan dari Raw

Lapis	Isi	Aturan
Silver	baris dipetakan ke kode kanonik indikator, wilayah, periode, satuan	aturan bernomor S01–S09; baris yang gagal masuk karantina dengan alasan, tidak dibuang
Gold	skema bintang bitemporal	satu fakta per (sumber, rilis, seri, wilayah, periode, rincian)
Data product	tampilan per pilar dengan kontrak	dibangkitkan dari YAML; kontrak diuji pada setiap jalan
Sajian	TPB-KG, paket level, Bravais, dasbor	hanya kelas yang boleh tayang

Inti rancangan gudang adalah pemisahan tiga sumbu waktu. **Waktu periode** adalah tahun atau bulan yang diukur oleh indikator. **Waktu rilis** adalah saat produsen menerbitkan nilai, beserta jenis buktinya. **Waktu catat** adalah saat baris ditulis ke tabel, yang disediakan oleh snapshot Iceberg. Query as-of memakai waktu rilis, sedangkan time travel Iceberg memakai waktu catat.



Gambar 3. Tiga sumbu waktu pada satu kunci (TPT nasional Agustus 2019). Angka yang benar pada hari terbitnya (5,28 % di BRS 5 November 2019) berbeda dari nilai terkini (5,23 %), dan keduanya tersimpan di gudang. Sumber: naskah penelitian gudang.

2.4 Stack teknologi

Tabel 2.3. Stack teknologi dan alasan pemilihannya (`code/infra/gudang/compose.yml`).

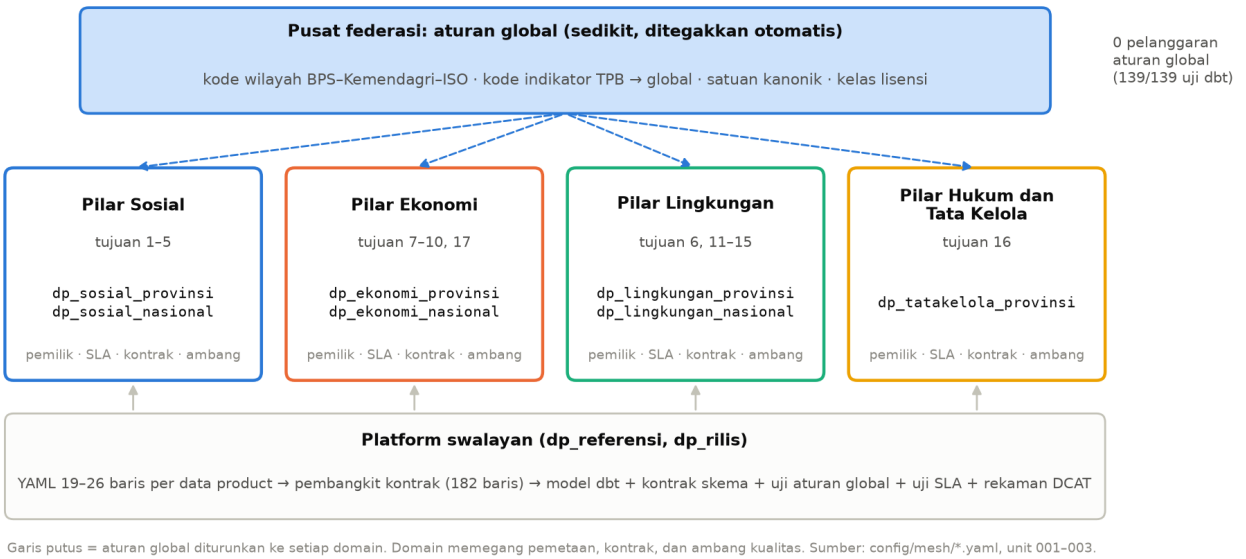
Fungsi	Alat dan versi	Alasan
Object storage	SeaweedFS 3.97 (antarmuka S3)	pengganti MinIO karena registri citra MinIO tidak terjangkau dari lingkungan pembangun; antarmuka S3 tetap standar
Format tabel dan katalog	Apache Iceberg, katalog REST 1.8.1	snapshot dan time travel untuk waktu catat
Query engine	Trino 476	sudah diukur pada benchmark sebelumnya; tersedia adaptor dbt
Pemuatan	PyIceberg 0.12.0	Silver hanya sekitar 1,5 juta baris, sehingga Spark (citra 2,4 GB) tidak diperlukan

Fungsi	Alat dan versi	Alasan
Transformasi dan uji	dbt-core 1.12.6, dbt-trino 1.10.6	model, uji, kontrak, dan lineage dalam satu alat
Orkestrasi	Dagster 1.13.26	aset Dagster sepadan dengan data product dan dapat membaca lineage dbt
Metadata	DCAT per data product, dbt docs, katalog Iceberg REST	OpenMetadata penuh memerlukan sekitar 40 GiB RAM dan tidak muat pada node 16 GB
Graf pengetahuan	RDF, validasi SHACL dengan pySHACL	ringan dan dapat berjalan pada satu simpul
Sajian	SQLite di server DSW (Lightsail 4 GB, 2 vCPU)	paket level dan Gold game dimuat ke memori; p95 pemeriksaan jawaban di bawah 1 ms

Pengembangan awal dilakukan di lingkungan cloud pada 20 Oktober 2026. Setelah itu, seluruh fase Silver, gudang, dan graf dijalankan ulang dari Raw di Mac peneliti (Apple Silicon, RAM 16 GB, Docker melalui Colima dengan VM 4 vCPU dan 8 GiB) pada 21 Oktober 2026. Angka gudang pada laporan ini berasal dari jalan di Mac tersebut.

2.5 Data mesh empat pilar TPB

Model operasional tata kelola yang dipilih adalah federasi atau data mesh. Domain mengikuti empat pilar TPB menurut Permen PPN/Kepala Bappenas Nomor 1 Tahun 2024 Pasal 4 ayat (3) sampai (6), karena pembagian tersebut juga menjadi struktur Metadata Indikator TPB dan sudah dikenal oleh pemangku kepentingan di Indonesia.



Gambar 4. Model federasi. Aturan global dibuat sedikit dan ditegakkan pusat secara otomatis, domain pilar memegang data product beserta pemilik, SLA, kontrak, dan ambang kualitasnya, sedangkan platform swalayan membangkitkan kontrak dari YAML.

Tabel 2.4. Domain dan data product (`code/config/mesh/*.yaml`).

Domain	Tujuan SDG	Data product
Pilar Sosial	1–5	`dp_sosial_provinsi`, `dp_sosial_nasional`
Pilar Ekonomi	7, 8, 9, 10, 17	`dp_ekonomi_provinsi`, `dp_ekonomi_nasional`
Pilar Lingkungan	6, 11, 12, 13, 14, 15	`dp_lingkungan_provinsi`, `dp_lingkungan_nasional`
Pilar Hukum dan Tata Kelola	16	`dp_tatakelola_provinsi`
Platform	–	`dp_referensi` (wilayah, indikator, satuan, konsep), `dp_rilis` (registri rilis)

Setiap data product dinyatakan sebagai satu berkas YAML sepanjang 19–26 baris yang memuat pemilik, kanal pelaporan masalah, SLA kesegaran, dan aturan kualitas. Pembangkit kontrak (`code/src/sdg_gudang/gudang/kontrak.py`) kemudian menurunkan dari setiap YAML sebuah model dbt, kontrak skema yang ditegakkan dbt, uji aturan global federasi, uji SLA, dan rekaman DCAT. Aturan global, yaitu kode wilayah, kode indikator, satuan, dan kelas lisensi, ditegakkan oleh pusat, sedangkan pemetaan, kontrak, dan ambang kualitas dipegang oleh domain.

2.6 Dari gudang ke pemakai

Pada Tahap II, Gold disambungkan ke empat pemakai: graf pengetahuan TPB-KG, kompilator paket level Liga Lakehouse versi 4, pemandu AI Bravais, dan dasbor indikator. Sambungan ini diuji melalui lima pengujian yang rencana analisisnya ditetapkan sebelum data dilihat.

Tabel 2.5. Pengujian Tahap II dan relevansinya bagi portofolio (`data/produk/`).

Pengujian	Yang diuji	Hasil pokok	Langkah
Uji integrasi	11 sumber dari 9 keluarga, 1.276 pasangan sumber × sumber	0,406 selisih terjelaskan; 79 dari 105 indikator berdata boleh tayang	07, 08
Uji graf	TPB-KG dibangun ulang dari Gold	85.734 tripel, sha256 identik dengan graf sebelumnya, 0 pelanggaran SHACL	05
Uji kompilasi paket	kelayakan level dan keterulangan	1.570 dari 3.820 kandidat lolos; hash paket, Parquet, dan SQLite identik pada dua jalan	09
Uji keterikatan Bravais	1.800 jawaban pada tiga kondisi	86,2 % jawaban terikat ke data saat memakai alat ber-provenans, 0,0 % tanpa alat	05
Uji operasi dan keterulangan	rebuild gudang dan kompilasi dua kali; latensi produksi	sidik Gold dan hash paket identik; p95 produksi 0,714–0,751 ms; memori tambahan 17,6 MB per worker	06, 09, 10

Sejak 23 Oktober 2026 paket produksi dipasang di Lightsail untuk Laga Liga Lakehouse, yaitu evaluasi pengguna daring yang berlangsung sampai 16 November 2026. Paket produksi dikompilasi dengan kunci rahasia, sehingga isinya berbeda dari paket evaluasi `afbcbeef…` dan tidak pernah di-commit. Kunci dan paket tersebut hanya tersimpan di Mac peneliti dan di server.

2.7 Fase dan keadaan pekerjaan

Tabel 2.6. Fase dan keadaannya pada 27 Oktober 2026.

Tahap dan fase	Keluaran	Keadaan
I.0 Tata kelola dan izin	piagam, RACI, inventaris aset, surat izin, berkas etik	draf lengkap; surat izin belum dikirim, sedangkan status tayang empat sumber diputuskan pada 22 Oktober
I.1 Data rujukan dan metadata	`dp_referensi`, dimensi wilayah tipe 2, tulang punggung graf, standar metadata	selesai; 11 uji lulus
I.2 Akuisisi multisumber	konektor 12 sumber, manifest, `dim_rilis`, rencana kapasitas	selesai
I.3 Silver, rekonsiliasi, kualitas	aturan yang dibekukan, Silver dengan karantina, `fakta_selisih`, laporan kualitas	selesai; dijalankan ulang di Mac
I.4 Gudang dan data mesh	skema bintang dbt, 9 data product berkontrak, Dagster, lineage, bukti rebuild	selesai; pemilik domain masih simulasi
I.5 Graf pengetahuan dan klaim berita	graf dengan SHACL, pemeriksa klaim as-of, korpus berita	sebagian; anotator sampel emas belum ditetapkan
II Pemakaian dan pengujian	TPB-KG, paket v4, Bravais, pemasangan di produksi	selesai 21 Oktober 2026
III Evaluasi pengguna daring	Laga, 23 Oktober–16 November	berjalan; data belum dianalisis sampai nomor etik terbit
Portofolio	sebelas folder bukti, salinan kode, laporan ini	bukti dan kode selesai 27 Oktober; berkas asesmen menyusul

2.8 Angka kunci

Tabel 2.7. Angka kunci proyek (Gold acuan `657df68e…`, paket evaluasi `afbcbeef…`). Semua berkas sumber ada di `data/`.

Ukuran	Nilai	Berkas sumber
Sumber data statistik / keluarga	11 / 9	`produk/uji-integrasi.json`
Rilis tercatat	2.662 data statistik + 16 berita	registri rilis; `gudang/m4_sidik_gold.json` (`dim_rilis` 2.678)
Observasi `fakta_observasi`	1.486.490	`gudang/m4_sidik_gold.json`
Pasangan `fakta_selisih`	1.377.573	`gudang/m4_sidik_gold.json`
Nilai pilihan (semua kelas / boleh tayang)	109.289 / 81.249	`gudang/m4_sidik_gold.json`
Data product berkontrak	9 (12 tabel `dp`)	`code/config/mesh/`, `gudang/m4_sidik_gold.json`
Uji dbt (node lulus)	139 / 139	`gudang/m4_sidik_gold.json`, `uji/uji-sla.json`
Pelanggaran aturan global federasi	0	uji dbt
Kelengkapan lineage	12/12 tabel data product = 1,00 (166 simpul, 320 sisi)	`gudang/m4_lineage.json`
Rebuild dari Raw	empat jalan, sidik Gold identik	`gudang/m4_sidik_gold.json`, `produk/uji-keterulangan.json`
Tripel TPB-KG / pelanggaran SHACL	85.734 / 0	`gudang/m5_kg_ringkasan.json`, `produk/uji-graf.json`
Kelayakan level paket v4	1.570 dari 3.820 kandidat lolos	`produk/uji-kompilasi.json`
p95 pemeriksaan jawaban di produksi	0,714–0,751 ms	`produk/latensi-produksi-*.json`
Uji SLA antarlapis (24 Okt)	45 dari 46 pemeriksaan lulus; API tanpa kompresi gagal, lulus dengan gzip	`uji/uji-sla.json`, `uji/uji-sla-api.json`

Ukuran	Nilai	Berkas sumber
Ingest GDELT 14–20 Okt	8,42 GB zip dialirkan pada 11,6 MB/s, 14 dari 14 aliran-hari lengkap	`uji/uji-sla-gdelt.json`

3. Bukti per Langkah Kerja

Bab ini memetakan hasil kerja ke sebelas unit skema menurut urutan pekerjaan yang sebenarnya, satu subbab untuk setiap folder `bukti/`. Untuk setiap langkah disajikan pertanyaan yang dijawab, pekerjaan yang dilakukan, bukti per elemen beserta jenisnya, alasan rancangan, dan catatan terbuka. Pemetaan rinci per KUK berada di `bukti/<langkah>/README.md`, dan setiap angka di bab ini menunjuk ke berkas di `data/`.

Tabel 3.1. Ringkasan status bukti per langkah (27 Oktober 2026). Status "lengkap" berarti setiap elemen mempunyai sedikitnya satu bukti; catatan terbuka dirinci pada subbab masing-masing dan dirangkum di Bab 5.

Langkah	Unit	Status	Catatan terbuka
01 Kebutuhan data	J.62DMS00.001.1	lengkap	pemilik domain masih simulasi; inventaris potret 20 Oktober
02 Rencana manajemen data	J.62DMS00.002.1	lengkap	pengisi peran pemilik domain dan jadwal kelas evaluasi belum diputuskan
03 Arsitektur data	J.62DMS00.003.1	lengkap	Perpres 39/2019 belum dicocokkan dengan teks resmi
04 Data rujukan dan master	J.62DMS00.008.1	lengkap	pemekaran sebelum 2012 belum dimodelkan; ruang nama IRI sementara
05 Metadata	J.62DMS00.009.1	lengkap	repositori metadata versi ringan; 72 satuan lokal belum dikurasi
06 Media penyimpanan	J.62DMS00.005.1	lengkap	kompatibilitas S3 bucket Lightsail belum diperiksa
07 Integrasi data	J.62DMS00.004.1	lengkap	414 selisih antarsumber belum terjelaskan oleh aturan beku
08 Kualitas data	J.62DMS00.012.1	lengkap	dua tindakan menunggu produsen; dua keterbatasan kerangka dicatat
09 Gudang data	J.62DMS00.014.1	lengkap	dua Gold dengan sidik berbeda; time travel belum diuji resmi
10 Big data dan operasi	J.62DMS00.007.1	lengkap	tanpa klaster terdistribusi; klaim dibatasi pada volume yang diuji
11 Pelindungan data pribadi	J.62PDP00.011.1	lengkap	nomor persetujuan etik resmi belum terbit

3.1 Kebutuhan data

J.62DMS00.001.1 Mengidentifikasi Kebutuhan Pengelolaan Data untuk Proses Bisnis · SKKNI 268/2020 · bukti dari fase tata kelola · status: lengkap

Langkah ini menjawab pertanyaan: data apa saja yang dimiliki dan dipakai organisasi, dan mengapa harus dikelola. Asesi menginventarisasi 38 aset data yang dimiliki dan dipakai pengelola Liga Lakehouse pada 20 Oktober 2026, yaitu 24 aset yang sudah ada dan 14 yang masih direncanakan, lalu menempatkan setiap aset pada tatanan kerja organisasi lengkap dengan steward, kelas lisensi, sensitivitas, dan masa retensinya. Dari inventaris itu diturunkan empat aturan penanganan aset dan dipilih model operasional tata kelola federasi.

Elemen	Pekerjaan	Bukti
1. Bentuk aset data dan aspek pengelolaannya	tiga fungsi organisasi yang memakai data; 38 aset dalam delapan kelompok menurut aktivitas pemakainya; empat aturan penanganan (Raw hanya bertambah, turunan dapat dibangun ulang, data pribadi dipisah, lisensi menentukan tayang); keselarasan dengan sasaran 2026; dua insiden yang menjadi aturan kontrak	`data/serkom/inventaris-aset-data.csv` (TL); uji kontrak dan kelayakan (L)
2. Aspek tata kelola aset data	setiap aset dipetakan ke tujuh tatanan kerja lewat kolom `pilar` dan `steward`; ranah keputusan data dipisah dari TI lewat kolom `ranah_tata_kelola`	kolom inventaris (TL); RACI langkah 02 (T)
3. Tipe model operasional tata kelola	model terpusat, tereplikasi, dan terdistribusi dibandingkan pada keadaan organisasi ini; federasi dipilih	tabel perbandingan di README (T)
4. Unsur data stewardship	tanggung jawab steward atas metadata; aturan yang berversi di git; enam isu kualitas yang sudah teridentifikasi; kepatuhan sebagai pemeriksaan otomatis	kolom `steward` (TL); `code/config/` (L)

Alasan rancangan. Inventaris diturunkan dari folder dan tabel yang nyata pada 20 Oktober 2026, bukan dari rancangan: ukuran diukur dengan `du`, dan nama tabel layanan diambil dari skema basis data DSW. Aset yang belum ada diberi status `rencana` beserta fasenya, sehingga asesor dapat membedakan yang sudah dikerjakan dari yang direncanakan. Model federasi dipilih karena sumber bertambah dari satu produsen menjadi lebih dari sepuluh dengan pengetahuan domain yang berbeda, sedangkan kode wilayah, kode indikator, dan satuan harus sama di semua pilar agar level lintas tujuan dan Kartu Keterkaitan dapat dibentuk. Peningkatan berkesinambungan dibuktikan dengan dua insiden yang perbaikannya menjadi aturan: benih acak paket v3 yang memuat label versi (kini parameter `versi_benih` dalam kontrak) dan penilai harness yang membaca satuan "per 1.000" sebagai angka (dijadwalkan sebagai versi penilai baru, bukan diterapkan diam-diam).

Catatan terbuka. Keempat domain pilar masih dipegang asesi sendiri, sehingga kolom `steward` menyebut peran, bukan orang yang sudah ditunjuk. Inventaris adalah potret 20 Oktober: sebagian aset berstatus `rencana` sudah dikerjakan pada fase M1–M5, dan keputusan repositori metadata berubah dari OpenMetadata menjadi versi ringan; kolom status sengaja tidak disegarkan agar sidik berkas tetap cocok, dan perubahannya dicatat di README. Surat izin untuk sumber kelas B masih draf.

3.2 Rencana manajemen data

J.62DMS00.002.1 Merencanakan Manajemen Data · SKKNI 268/2020 · bukti dari fase tata kelola dan gudang · status: lengkap

Langkah ini menjawab pertanyaan: siapa memutuskan apa, dengan prinsip apa, dan kapan. Asesi menulis piagam tata kelola data Liga Lakehouse pada 20 Oktober 2026, sebelum gudang dibangun, yang memuat enam faktor penggerak terukur, visi, lima misi, tujuh prinsip, dan delapan kriteria keberhasilan yang dibekukan sampai 31 Desember 2026. Tanggung jawab dituangkan dalam matriks RACI (Responsible, Accountable, Consulted, Informed) 24 kegiatan × 10 peran dengan aturan satu penanggung gugat per kegiatan.

Elemen	Pekerjaan	Bukti
1. Faktor penggerak, visi, misi, prinsip	enam faktor penggerak dari pengukuran dan dokumen yang ada (misalnya 33 dari 1.435 sel beririsan berbeda antara dua kanal BPS); visi, lima misi, tujuh prinsip DAMA-DMBOK dengan penerapannya; kesiapan sepuluh proses internal; delapan kriteria keberhasilan terukur	README langkah 02 (T, TL)
2. Struktur dan tanggung jawab	struktur tujuh peran internal dan empat pihak luar; RACI 24 kegiatan × 10 peran, termasuk tiga kegiatan PDP yang ditambahkan 26 Oktober	`data/serkom/raci.csv` (T)
3. Kerangka waktu	empat periode sasaran, aturan pembekuan kriteria bersama praregistrasi, tata waktu M0–M9	README langkah 02 (T)
4. Faktor penentu keberhasilan	delapan faktor dengan ukuran dan target; status dicatat pada 20 dan 24 Oktober	`data/gudang/m4_sidik_gold.json`, `m4_lineage.json`, `data/produk/uji-keterulangan.json` (TL)

Alasan rancangan. Setiap kegiatan punya tepat satu penanggung gugat supaya selalu jelas siapa yang memutuskan; bila pengerja dan penanggung gugatnya sama, ditulis A/R. Prinsip dipasangkan dengan penerapannya karena prinsip yang tidak punya bentuk teknis tidak akan ditegakkan. Kriteria keberhasilan dibekukan pada M0 bersama praregistrasi, dan ambang yang menyangkut hasil penelitian tidak boleh diubah setelah data terkait dilihat. Status 24 Oktober hanya memuat angka yang ada di `data/`: sidik Gold identik pada empat rebuild, lineage 166 simpul dan 320 sisi tanpa data product yang terputus dari Raw, dan 139 node dbt lulus.

Catatan terbuka. Pengisi peran pemilik domain belum diputuskan resmi; pilihan (a), yaitu asesi sendiri sebagai simulasi, berjalan de facto, sedangkan pilihan (b), empat kelompok mahasiswa Pergudangan Data, masih terbuka. Jadwal kelas evaluasi (M7) bergantung pada persetujuan etik. Dua faktor belum pernah diukur: kesegaran, karena konektor belum berjadwal, dan kemudahan menambah sumber.

3.3 Arsitektur data

J.62DMS00.003.1 Merencanakan Arsitektur Data · SKKNI 268/2020 · bukti dari fase tata kelola dan gudang · status: lengkap

Langkah ini menjawab pertanyaan: model tata kelola apa yang cocok dengan budaya dan peraturan organisasi. Asesi memilih model federasi (data mesh) dengan menguraikan arah tarikan setiap faktor penggerak: yang menuntut pengetahuan domain ditarik ke desentralisasi, yang menuntut kode dan lisensi yang sama ditarik ke sentralisasi. Hasilnya empat domain pilar TPB memiliki data product masing-masing, sedangkan tim platform menegakkan empat aturan global secara otomatis.

Elemen	Pekerjaan	Bukti
1. Model operasional tata kelola	lima unsur tata kelola dipetakan ke strategi TI, arsitektur data, dan integrasi aplikasi; arah tarikan lima penggerak; model federasi diwujudkan sebagai sembilan data product berkontrak (12 tabel `dp`)	`code/config/mesh/*.yaml` (L); `data/gudang/m4_sidik_gold.json` (TL)
2. Pengaruh budaya organisasi	lima faktor penerimaan kedisiplinan dan lima faktor kemampuan beradaptasi; siklus semester sebagai faktor penentu	README langkah 03 (T)

Elemen	Pekerjaan	Bukti
3. Pengaruh peraturan	tujuh peraturan dan ketentuan (UU 16/1997, Perpres 39/2019, UU 14/2008, UU 28/2014, UU 27/2022, lisensi sumber, kode etik penelitian) beserta pola pikir yang dibentuk; lima penanda dini bila model tidak tepat	README langkah 03 (T)

Alasan rancangan. Faktor budaya yang paling menentukan adalah siklus semester. Bila peran domain diisi mahasiswa, orangnya berganti setiap semester, sehingga pengetahuan domain hanya bertahan bila tersimpan di kontrak, metadata, dan uji yang berjalan sendiri. Karena itu model ini menempatkan aturan yang dapat dieksekusi di atas dokumen yang harus dibaca, dan wujudnya terlihat pada fase gudang: setiap data product adalah satu berkas YAML 19–26 baris, dan pembangkit kontrak menurunkan darinya model dbt, kontrak skema, uji aturan global, uji SLA, dan rekaman DCAT. Tiga keputusan teknis berubah dari bagan 20 Oktober saat dibangun, masing-masing dengan alasan yang terukur: Spark tidak dipakai (langkah 10), orkestrator ditetapkan Dagster (langkah 09), dan katalog metadata memakai versi ringan (langkah 05). UU 16/1997 membedakan statistik dasar oleh BPS dan statistik sektoral oleh instansi, sehingga data KLH, KKP, dan BNPB sah sebagai sumber resmi dengan pemilik berbeda; UU 28/2014 menjadi dasar kebijakan berita: angka tidak dilindungi hak cipta, sehingga yang disimpan hanya tupel angka dan cuplikan paling banyak dua kalimat.

Catatan terbuka. Sisi organisasi federasi (dua orang berbeda memegang domain berbeda di bawah aturan global yang sama) belum pernah diuji; sisi teknisnya terbukti lewat uji aturan global yang berjalan tanpa pelanggaran. Rujukan Perpres 39/2019 belum dicocokkan pasal demi pasal dengan teks resmi.

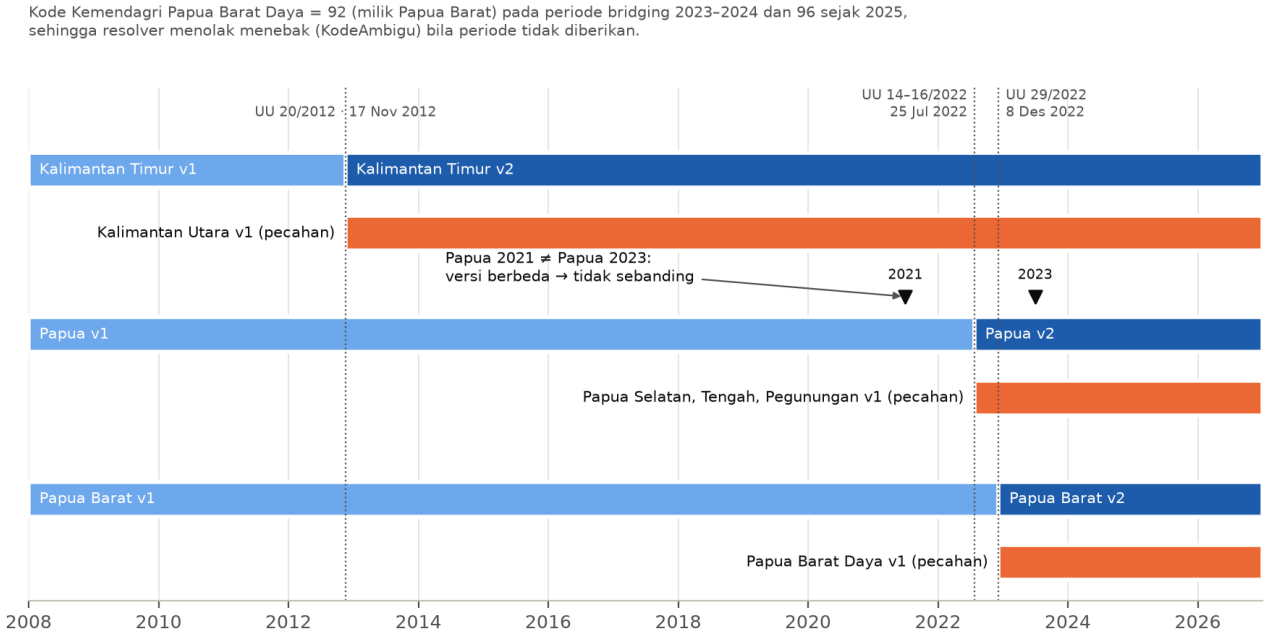
3.4 Data rujukan dan master

J.62DMS00.008.1 Mengelola Reference and Master Data · SKKNI 268/2020 · bukti dari fase data rujukan dan Silver · status: lengkap

Langkah ini menjawab pertanyaan: kode wilayah, indikator, dan satuan mana yang menjadi acuan bersama semua sumber. Lima kebutuhan data rujukan dan master diturunkan dari masalah yang benar-benar terjadi saat menggabungkan lebih dari sepuluh sumber, lalu dibangun dimensi wilayah tipe 2 yang tahan pemekaran, tabel padanan kode BPS, Kemendagri, dan ISO per periode, dimensi indikator TPB berpadanan kode global, satuan kanonik, dan tulang punggung graf pengetahuan yang divalidasi SHACL.

Elemen	Pekerjaan	Bukti
1. Kebutuhan reference dan master data	lima kebutuhan dari kesalahan nyata; analisis delapan sumber rujukan; definisi data yang dipakai semua tabel (`wilayah_kode`, masa berlaku versi, `padanan_global`, penyebut satuan rasio)	README langkah 04 (T)
2. Membangun	`dim_pilar` (4), `dim_indikator` (109), `dim_satuan` (18 kanonik, 91 di gudang dengan satuan lokal), `alias_wilayah` (82), `dim_wilayah` tipe 2 (42 baris), `padanan_kode_wilayah` (186), `peta_tabel_indikator` (76 tabel, 22 lewat keputusan steward), tulang punggung KG 3.305 tripel lulus SHACL	`data/gudang/m4_sidik_gold.json` (tabel `dp_referensi_*`) (TL); `code/src/sdg_gudang/referensi.py` (L)

Elemen	Pekerjaan	Bukti
3. Menggunakan dan mengelola perubahan	satu resolver **Rujukan** untuk semua konsumen; lima jenis perubahan dengan cara penanganan yang tidak menghapus keadaan lama; 11 uji unit termasuk kasus Papua dan SIGN-SMART	`code/tests/unit/test_sdg_gudang_referensi.py` (L); `data/gudang/m5_kg_ringkasan.json` (TL)



Gambar 5. Dimensi wilayah tipe 2: versi provinsi sebelum dan sesudah pemekaran 2012 dan 2022. Pengamatan Papua 2021 dan Papua 2023 jatuh pada versi wilayah yang berbeda, sehingga deret yang melintasi pemekaran ditandai tidak sebanding.

Alasan rancangan. Aspek kritis unit ini adalah ketepatan definisi data, dan tiga definisi lahir dari kesalahan yang benar-benar terjadi: kode Papua tertukar antara BPS (94) dan Kemendagri (91); `KODE_PROV` pada GeoJSON 38 provinsi tidak unik (empat provinsi Papua berkode 91), sehingga tidak dapat dipakai sebagai kunci; dan satuan "per 1.000" terbaca sebagai nilai oleh penilai otomatis jawaban Bravais versi pertama. Perubahan dikelola tanpa menebak: kode Kemendagri Papua Barat Daya sama dengan Papua Barat (92) pada periode bridging 2023 dan 2024, lalu menjadi 96 mulai 2025, dan resolver menimbulkan galat **KodeAmbigu** bila periode tidak diberikan. Setelah dimuat ke gudang, tabel yang sama muncul sebagai `dp_referensi_wilayah` (42 baris), `dp_referensi_indikator` (109), `dp_referensi_satuan` (91), dan `dp_referensi_konsep` (1.126); graf penuh TPB-KG di atas tulang punggung ini memuat 85.734 tripel dan lulus SHACL tanpa pelanggaran.

Catatan terbuka. Nama tabel v3 `sdg3_3_2_1_v1584` menyesatkan karena isinya angka kematian bayi, bukan 3.2.1; isi level tidak terpengaruh. Arti tanda `*` dan `()` baru dipastikan dari legenda halaman Metadata SDGs Bappenas, belum dari buku metadata 2024. Pemekaran sebelum 2012 belum dimodelkan, dan ruang nama IRI graf masih sementara.

3.5 Metadata

J.62DMS00.009.1 Mengelola Metadata · SKKNI 268/2020 · bukti dari fase data rujukan, gudang, graf, dan uji keterikatan · status: lengkap

Langkah ini menjawab pertanyaan: bagaimana orang lain tahu isi, asal, dan pemilik setiap data. Kebutuhan metadata ditetapkan dari tiga kelompok konsumen yang pertanyaannya berbeda (pemain dan Bravais, pemilik domain, tim platform), lalu disusun standar wajib per data product dengan kosakata DCAT dan PROV serta padanan konsep SDMX. Metadata tidak ditulis tangan: rekaman DCAT, manifest sha256, kontrak dbt, dan lineage dibangkitkan dari konfigurasi data product pada setiap jalan job.

Elemen	Pekerjaan	Bukti
1. Kebutuhan metadata	tiga konsumen dipetakan ke jenis metadata bisnis, tata kelola, dan teknis; arsitektur empat lapis; standar wajib per data product, distribusi, dan observasi	README langkah 05 (T)
2. Membangun metadata	`metadata.jsonld` dan manifest dari pembangun `dp_referensi`; 9 rekaman DCAT per data product; kontrak dbt dari YAML; lineage 166 simpul dan 320 sisi; TPB-KG 85.734 tripel sebagai metadata semantik	`data/gudang/m4_lineage.json`, `m5_kg_ringkasan.json`, `data/produk/uji-graf.json` (TL); `code/src/sdg_gudang/gudang/kontrak.py`, `kg.py`, `lineage.py` (L)
3. Menggunakan metadata	metadata didistribusikan di tempat yang sama dengan data (tabel `dp_referensi_*`, `dp_rilis`, kolom provenans per baris); analisis cakupan indikator dari metadata saja; provenans sebagai alat Bravais; tiga mekanisme pemeliharaan	`data/produk/uji-keterikatan.json` (TL); uji `test_gudang_kontrak` (L)

Alasan rancangan. OpenMetadata tidak dipasang karena spesifikasi produksinya memerlukan sekitar 40 GiB RAM dan tidak muat bersama Trino pada node 16 GB; batasan variabel unit membolehkan repositori metadata di alat lain, sehingga dipakai versi ringan: rekaman DCAT per data product, katalog Iceberg REST, dokumentasi dbt, dan lineage JSON. Metadata tidak ditulis tangan agar tidak tertinggal dari datanya: aset Dagster `kontrak_mesh` dan uji `test_gudang_kontrak` gagal bila berkas yang di-commit berbeda dari konfigurasinya. Dua contoh pemakaian membuktikan gunanya. Tanpa membaca nilai data, metadata menunjukkan bahwa baru 51 dari 105 indikator katalog TPB (48,6 %) mempunyai tabel di Gold v3, dan hasil ini menjadi prioritas akuisisi. Pada uji keterikatan (penilai v2), dari 595 jawaban Bravais dengan alat ber-provenans 513 (86,2 %) terikat ke angka gudang, sedangkan dari 600 jawaban tanpa alat 0 (0,0 %) terikat; selisih proporsinya 0,862 dengan selang kepercayaan 0,831–0,888.

Catatan terbuka. Pencarian metadata lintas data product masih lewat berkas JSON-LD dan katalog Iceberg, belum lewat antarmuka katalog. Metadata DCAT baru menjangkau 9 data product; tabel Bronze dan Silver baru punya metadata teknis. 72 satuan lokal belum dikurasi, dan pemeriksaan klaim berita baru menjangkau dua indikator.

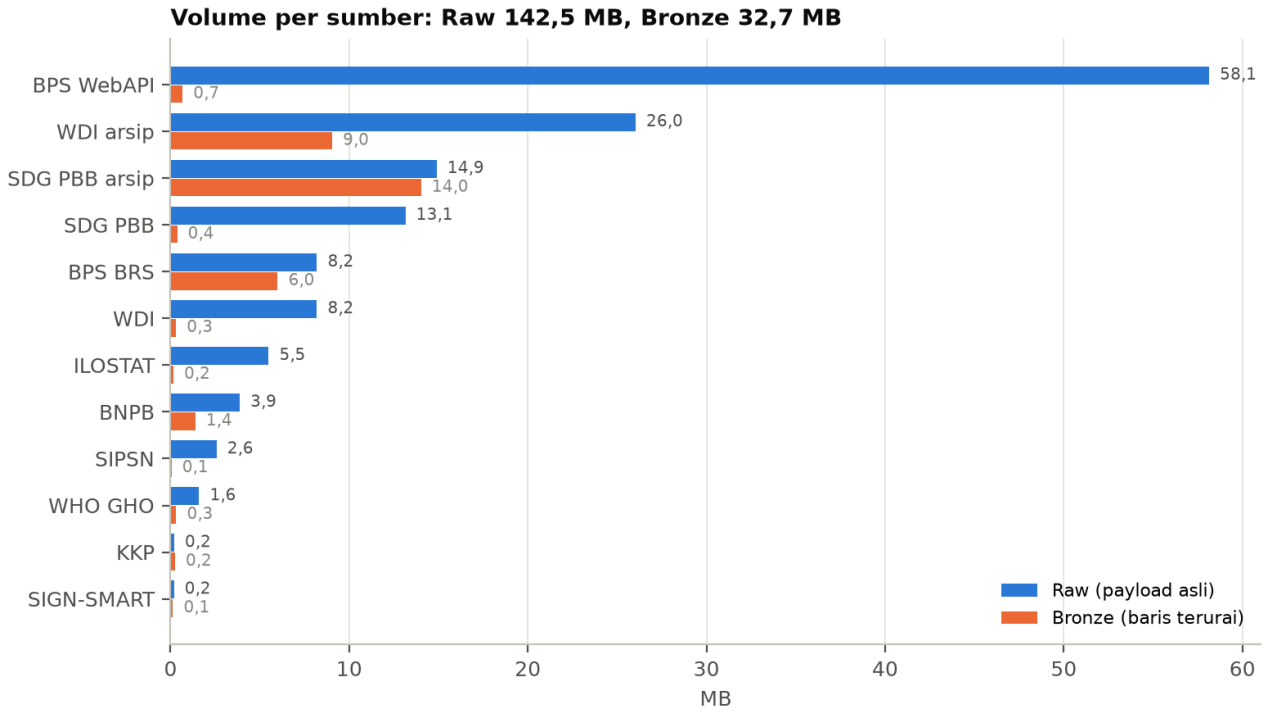
3.6 Media penyimpanan

J.62DMS00.005.1 Merencanakan Media Penyimpanan Data · SKKNI 268/2020 · bukti dari fase akuisisi, gudang, dan uji operasi · status: lengkap

Langkah ini menjawab pertanyaan: seberapa besar datanya, akan tumbuh berapa, dan disimpan di mana. Volume setiap lapis diukur per sumber setelah akuisisi 12 sumber selesai pada 20 Oktober 2026, lalu

pertumbuhannya ditaksir dari frekuensi rilis yang terukur di registri 2021–2026. Karena volumenya kecil, yang menentukan pilihan media bukan kapasitas simpan melainkan jenis data dan memori komputasi.

Elemen	Pekerjaan	Bukti
1. Analisis jumlah data	Raw 142,5 MB dalam 889 berkas, Bronze 32,7 MB dengan 1.607.907 baris, manifest 3,7 MB, 2.662 rilis; payload global 2,63 GB yang hanya disimpan ekstraknya; pertumbuhan 150–250 MB per tahun tanpa berita	`data/gudang/volume.json` (TL)
2. Rencana volume	volume per lapis arsitektur; model pertumbuhan $V(t) = V_0 + t \cdot \Sigma r \quad s$; taksiran tiga tahun 0,6–0,9 GB tanpa berita	README langkah 06 (T)
3. Opsi, masa simpan, biaya, rencana	opsi per jenis data (object storage, Iceberg, SQLite, RDF); masa simpan per jenis; lima opsi tempat lakehouse dengan biaya sampai 31 Desember 2026; rencana lima langkah	README langkah 06 (T); `data/produk/latensi-produksi-*.json` (TL)



Gambar 6. Volume per sumber pada lapis Raw dan Bronze. Arsip WDI dan arsip basis data SDG PBB adalah sumber terbesar setelah BPS WebAPI, karena menyimpan setiap versi; payload global yang hanya diekstrak tidak disimpan utuh.

Alasan rancangan. Volume data kecil, sehingga batas yang perlu diawasi adalah ruang kosong Mac dan memori komputasi, bukan kapasitas simpan; biaya simpan dapat diabaikan dibandingkan biaya komputasi (kurang dari 1 GB tiga tahun muat di bucket USD 1 per bulan, sedangkan instance 8 atau 16 GB untuk komputasi sekitar USD 75 atau 144 untuk masa M4–M8). Raw disimpan selamanya karena produsen menimpa nilai lama di kanal daring, sehingga Raw menjadi satu-satunya bukti angka yang pernah terbit; payload global yang hanya diekstrak disimpan sebagai sha256, ukuran, dan URL agar dapat diunduh ulang dan diverifikasi. Di sisi sajian, memuat paket v4 menambah memori 17,6 MB per worker API di Lightsail 4 GB, jauh di bawah ambang 150 MB. Yang benar-benar terjadi pada M4: lakehouse dijalankan ulang di Mac (Colima 4 vCPU, 8 GiB) dengan SeaweedFS berantarmuka S3, tanpa instance baru; rebuild penuh dari Raw

338–366 detik dengan hash identik.

Catatan terbuka. Kompatibilitas S3 bucket Lightsail belum diperiksa, dan salinan ke bucket belum dikonfirmasi. Volume berita belum masuk taksiran; deduplikasi isi snapshot BPS belum dijalankan; memori komponen lakehouse belum diukur dengan `docker stats`.

3.7 Integrasi data

J.62DMS00.004.1 Merencanakan Integrasi Data · SKKNI 268/2020 · bukti dari fase akuisisi sampai gudang dan uji integrasi · status: lengkap

Langkah ini menjawab pertanyaan: bagaimana sebelas sumber digabung tanpa ada angka yang hilang atau ditebak. Integrasi tidak menggabungkan nilai di Silver: setiap angka yang pernah terbit dari setiap sumber tetap tersimpan dengan kunci bersama, dan penggabungan hanya terjadi saat memilih `nilai_pilihan` di Gold dengan alasan yang ikut tersaji. Aturan pemetaan, kelas sebab selisih, dan prioritas pemilihan nilai dibekukan dalam praregistrasi yang di-commit sebelum data dibandingkan.

Elemen	Pekerjaan	Bukti
1. Kebutuhan integrasi	kebutuhan konsumen (satu nilai pilihan, semua nilai tetap dapat dipanggil); kunci relasi antardata; tabel padanan 105 seri dalam 36 konsep; business rule S01–S09, K0a–K9, dan prioritas nilai pilihan	`data/gudang/m3_rekonsiliasi_ringkasan.json` (sha256 dan commit berkas beku) (TL); `code/config/rekonsiliasi/` (L)
2. Data discovery	katalog 12 sumber; profil kualitas tujuh dimensi per sumber sebagai syarat integrasi; konsistensi antarsumber: 1.376.297 pasangan rilis × rilis dan 1.276 pasangan sumber × sumber	`data/gudang/m3_kualitas.json`, `data/produk/uji-integrasi.json` (TL)
3. Data lineage	lineage baris (sha256 Raw di setiap baris) dan aset (166 simpul, 320 sisi, 12 dari 12 data product berjalur ke Raw); ekspor ke paket level identik byte pada dua rebuild; lima usulan perbaikan aliran	`data/gudang/m4_lineage.json`, `data/produk/uji-keterulangan.json` (TL)
4. Profil data	identitas lima tempat per sel Bronze pada 54 tabel; 1.487.727 baris Silver dan karantina bersidik Raw cocok; kelas lisensi dan pagar privasi ditegakkan mekanis	`data/gudang/silver_ringkasan.json` (TL); `code/src/sdg_gudang/silver/` (L)

Alasan rancangan. Integrasi tidak membuang nilai. Setiap sel kandidat dari Bronze berakhir di tepat satu dari lima tempat, dan identitas n(sel) = n(Silver) + n(karantina) + n(kosong) + n(di luar tingkat) + n(gabung) diuji pada setiap tabel. Kode wilayah yang ambigu masuk karantina dan tidak ditebak: SIGN-SMART memberi kode `ID-AC` pada Aceh dan empat provinsi Papua baru, sehingga 650 sel dikarantina. Rekonsiliasi dibaca pada dua tingkat yang berbeda maknanya. Pada tingkat rilis × rilis, 90,3 % pasangan sama dan hampir semua selisih (81.090 dari 84.849) adalah revisi antarvintage dari produsen yang sama, dan itulah alasan gudang menyimpan setiap rilis. Pada tingkat sumber × sumber, 283 dari 697 selisih (0,406; Wilson 95 % 0,370–0,443) terjelaskan oleh aturan yang dibekukan, dan angka itu sengaja tidak dinaikkan dengan menambah kelas setelah data dilihat. Aspek kritis resmi unit ini, ketepatan menganalisis aliran data, dibuktikan oleh lineage tingkat baris yang membuat setiap angka di data product, dan selanjutnya di paket level, dapat ditelusuri ke berkas unduhan asalnya.

Catatan terbuka. 414 selisih antarsumber belum terjelaskan; kelas sebab vintage antarkustodian (WDI × WHO menyalin ronde UN IGME berbeda) dicatat untuk praregistrasi berikutnya dan tidak diterapkan surut.

Konsistensi baru diukur pada 32 konsep berpasangan, dan sumber sektoral belum punya pembanding antarkeluarga.

3.8 Kualitas data

J.62DMS00.012.1 Mengelola Kualitas Data · SKKNI 268/2020 · bukti dari fase Silver dan kualitas, gudang, dan uji integrasi · status: lengkap

Langkah ini menjawab pertanyaan: bagaimana masalah kualitas ditemukan, diurutkan, diperbaiki, dan dipantau. Kerangka tujuh dimensi kualitas dengan parameter, standar minimum, dan alasan yang menunjuk pemakainya dibekukan di git sebelum data multisumber dinilai, sehingga hasil yang buruk tidak dapat mengubah ambang.

Elemen	Pekerjaan	Bukti
1. Kerangka kualitas data	tujuh dimensi (keterpetakan ≥ 0,95; keunikan 0; validitas ≥ 0,99; kelengkapan ≥ 0,90; ketepatan waktu dan konsistensi dilaporkan; keterlacakan 1,00) dengan alasan per pemakai; dibekukan pada commit `89e0387`	bidang `standar` di `data/gudang/m3_kualitas.json` (TL)
2. Penilaian awal dan akar masalah	1.602.998 baris Bronze dari 12 sumber; lima pelanggaran di empat sumber dengan akar masalah masing-masing; empat karantina kecil yang tetap ditelusuri; dua perbaikan di hulu	`data/serkom/kualitas-per-sumber.csv`, `data/gudang/m3_kualitas.json` (TL)
3. Prioritas perbaikan	skor = baris terdampak × bobot dampak (3 bila dipakai paket level, 2 bila terpetakan katalog TPB, 1 selain itu); 47 masalah dengan tindakan dan pemilik	`data/serkom/prioritas-perbaikan.csv` (TL)
4. Operasi koreksi, ukur, pantau	koreksi di aturan, bukan di data (73 satuan, agregasi S09); ukur ulang dari Raw kurang dari sepuluh menit; 139 node dbt di setiap jalan; lima insiden ditangani dengan pola yang sama	`data/gudang/m4_sidik_gold.json`, `silver_ringkasan.json` (TL); `code/src/sdg_gudang/silver/kualitas.py` (L)

	keterpetakan (≥ 0,95)	kunci ganda beda nilai (0)	validitas (≥ 0,99)	kelengkapan provinsi (≥ 0,90)	bukti tanggal lemah	keterlacakan (1,00)
BPS	1,000	0	1,000	0,959	0,03	1,000
SDG PBB (API)	0,999	0	0,996	–	0,00	1,000
SDG PBB (arsip 48)	1,000	0	0,999	–	0,00	1,000
WDI (terkini)	1,000	0	1,000	–	0,00	1,000
WDI (arsip 142)	1,000	0	1,000	–	0,00	1,000
ILOSTAT	1,000	0	1,000	–	0,00	1,000
WHO GHO	0,999	2 ✗	1,000	–	0,02	1,000
BNPB	0,995	0	1,000	0,653 ✗	0,00	1,000
KKP	0,997	0	1,000	0,974	1,00	1,000
SIGN-SMART	0,870 ✗	0	0,880 ✗	–	1,00	1,000
SIPSN	0,155 ✗	0	1,000	0,953	1,00	1,000

✗ = di bawah standar minimum praregistrasi M3; – = tidak berlaku (sumber nasional, tanpa dimensi provinsi). Kolom bukti tanggal lemah dilaporkan tanpa ambang.

Gambar 7. Nilai dimensi kualitas per sumber; sel bertanda silang berada di bawah standar minimum. Sumber: naskah

penelitian gudang.

Alasan rancangan. Tujuh dari sebelas profil sumber memenuhi semua standar. Lima pelanggaran ada di empat sumber dan masing-masing mempunyai akar masalah yang dapat ditunjuk: SIPSN (keterpetakan 0,155, data berada di tingkat kabupaten/kota), SIGN-SMART (keterpetakan 0,870 karena kode `ID-AC`, validitas 0,880 karena emisi bersih kehutanan bernilai negatif), WHO GHO (dua kunci ganda bernilai beda, duplikat di sumber), dan BNPB (kelengkapan 0,653 karena tabel kejadian hanya memuat provinsi terdampak). Keterlacakan bernilai 1,000 pada semua sumber: 1.487.727 dari 1.487.727 baris cocok dengan manifest. Dua temuan diperbaiki di hulu, bukan dikarantina: pola satuan "Rupiah/Jam" yang tidak tertangkap (393 sel) dan pola `gg co2e` yang memetakan Gg CO2e ke ton dengan faktor 1, padahal seharusnya 1.000. Nilai negatif SIGN-SMART tidak dikoreksi, karena yang salah adalah kerangka, bukan datanya; standar tidak diubah setelah hasil terlihat, dan pembacaannya dicatat untuk praregistrasi berikutnya. Insiden tanggal rilis PBB (Bab 4.5) menunjukkan siklus itu berjalan: kesalahan yang lolos dari 137 uji kontrak diperbaiki di aturan, dua uji dbt kewajaran tanggal ditambahkan, dan angka sebelum perbaikan tetap dilaporkan.

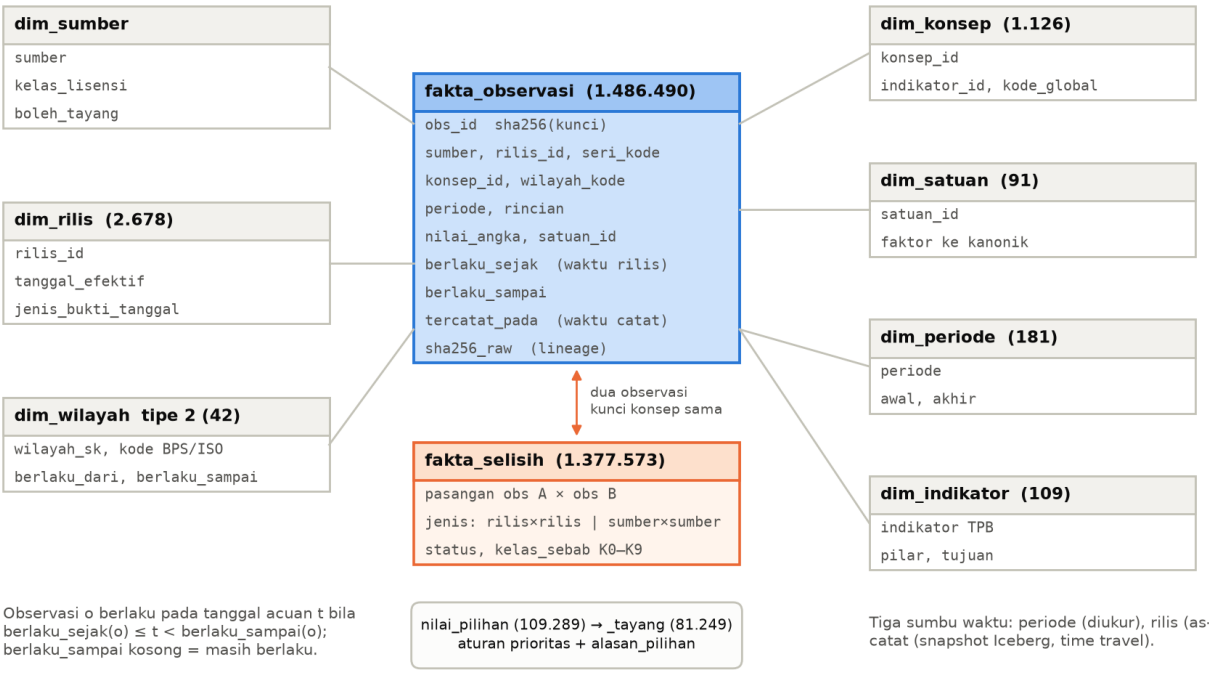
Catatan terbuka. Dua tindakan prioritas menunggu pihak luar: tabel kode SIGN-SMART dari KLH/BPLH dan berkas asli BNPB 2000 lewat unduhan tangan. Dua keterbatasan kerangka (validitas untuk `massa_setara`, kelengkapan untuk tabel kejadian) belum masuk praregistrasi berikutnya. Pemantauan baru bersifat per jalan, belum berjadwal.

3.9 Gudang data

J.62DMS00.014.1 Membuat Data Warehouse · SKKNI 268/2020 · bukti dari fase gudang, uji integrasi, kompilasi, dan operasi · status: lengkap

Langkah ini menjawab pertanyaan: bagaimana setiap versi angka disimpan, dipanggil ulang, dan dibangun ulang sama persis. Gudang berskema bintang bitemporal dibangun di lapis Gold: `fakta_observasi` menyimpan setiap nilai dari setiap rilis dengan interval berlaku, sehingga angka sebagaimana terbit pada tanggal tertentu dapat dipanggil ulang dengan query as-of, dan `nilai_pilihan` dihitung oleh aturan prioritas yang tercatat alih-alih membuang nilai.

Elemen	Pekerjaan	Bukti
1. Kebutuhan data warehouse	lima kebutuhan dengan asal dan wujudnya di gudang; sumber: Silver dari 12 sumber, `dim_sumber` 15 baris, `dim_rilis` 2.678 rilis	README langkah 09 (T); `data/gudang/m4_sidik_gold.json` (TL)
2. Rancangan skema dan alat ETL	struktur berlapis; skema bintang dua fakta tujuh dimensi; tiga sumbu waktu; enam alat dengan alasan (Iceberg, SeaweedFS, Trino, PyIceberg, dbt, Dagster)	README langkah 09 (T)
3. Membangun dan mendokumentasikan	11 model `gold` dan 12 model `dp`; 139 node dbt lulus (23 model, 1 seed, 115 uji data); `dbt docs` dan DCAT	`code/dbt/gudang_sdg/` (L); 23 tabel di `data/gudang/m4_sidik_gold.json` (TL)
4. Memasang, menjalankan, memantau	`make m4-naik` dengan versi dipatok; job Dagster `gudang_penuh`; metadata materialisasi per aset; empat rebuild bersidik sama; dua insiden pemasangan ditangani	`data/produk/uji-keterulangan.json`, `sidik-gold.json`, `uji-kompilasi.json` (TL); `code/src/sdg_gudang/gudang/orkestrasi.py` (L)



Gambar 8. Skema bintang bitemporal di lapis Gold. `fakta_observasi` menyimpan setiap nilai dari setiap rilis dengan interval berlaku; `fakta_selisih` memasangkan dua observasi berkunci konsep sama; `nilai_pilihan` dihitung aturan prioritas dan menyertakan alasannya.

Alasan rancangan. Observasi o berlaku pada tanggal acuan t bila `berlaku_sejak(o) ≤ t` dan `berlaku_sampai(o)` kosong atau `t < berlaku_sampai(o)`. Dengan aturan ini TPT Agustus 2019 dapat dipanggil sebagaimana terbit pada 5 November 2019 maupun sebagaimana tertulis di tabel BPS sekarang. Gudang tidak memakai skor kepercayaan beku seperti fusi data: semua observasi disimpan, dan nilai pilihan dihitung oleh aturan prioritas yang tercatat (BPS, lalu sektoral nasional, lalu kustodian internasional resmi, lalu Bank Dunia, lalu estimasi) dengan alasan pilihan pada setiap baris; untuk sajian, calon dari sumber yang tidak boleh tayang dikeluarkan sebelum pemilihan, sehingga terbentuk `nilai_pilihan` (109.289 baris) dan `nilai_pilihan_tayang` (81.249 baris). Aspek kritis resmi unit ini, ketepatan membuat sistem sesuai rancangan, dibuktikan oleh uji dbt yang menegakkan rancangan (relasi ke dimensi, interval bitemporal tidak mundur, identitas jumlah Silver–Gold, kewajaran tanggal rilis, hanya kelas terbuka pada sajian) dan oleh sidik Gold `657df68e…` yang identik pada empat jalan dari nol setelah stack dan volumenya dihapus. Sidik dihitung sebagai sha256 atas baris terurut setiap tabel melalui Trino, sehingga tidak bergantung pada bita Parquet maupun snapshot Iceberg. Rantai ke produk ikut diuji: dua kompilasi paket v4 memberi hash paket, Gold Parquet, dan Gold SQLite yang identik, dan 1.570 dari 3.820 level kandidat lolos uji kelayakan.

Catatan terbuka. Dua Gold dengan sidik berbeda beredar: Gold acuan `657df68e…` untuk laporan dan pengujian, dan Gold Laga `1b8c95e3…` yang hanya berbeda kelas lisensi empat sumber. Snapshot Iceberg ada, tetapi query time travel belum diuji sebagai bagian pengujian resmi. Gudang baru berjalan di satu node pengembangan.

3.10 Big data dan operasi

J.62DMS00.007.1 Merancangbangun Big Data · SKKNI 268/2020 · bukti dari fase akuisisi, gudang, korpus berita, dan uji operasi · status: lengkap

Langkah ini menjawab pertanyaan: pemrosesan apa yang benar-benar dibutuhkan pada volume ini, dan apakah memenuhi SLA. Prinsipnya mengukur dulu, baru memilih alat. Data yang disimpan ternyata kecil, sedangkan data yang besar, yaitu arsip global dan GDELT berukuran terabita, dibatasi oleh jaringan dan bukan oleh CPU. Karena itu Spark tidak dipakai, dan keputusan itu diuji dengan pembanding Spark nyata pada data yang sama.

Elemen	Pekerjaan	Bukti
1. Tipe data processing	15 sumber dikelompokkan menurut kecepatan terbit dan ukuran satuan terbit; tipe per kelompok: batch rebuild penuh untuk statistik resmi, batch streaming untuk arsip global dan GDELT, mikro-batch untuk RSS; tanpa streaming sejati karena tidak ada konsumen berlatensi di bawah satu jam	`data/gudang/volume.json` (TL)
2. Layer big data	ingestion (konektor per sumber, manifest sha256, 907 berkas Raw berintegritas 1,0), processing (Raw, Bronze, Silver, Gold lewat job `gudang_penuh`), presentation (9 data product, TPB-KG, indeks klaim, paket level, SQLite Bravais)	`code/src/sdg_gudang/akuisisi/` (L)
3. Arsitektur big data	opsi teknologi per layer dengan pengukuran; SLA per lapis; delapan risiko dengan mitigasi; cabang jalur berita	`data/uji/banding-spark.json` (TL); `code/config/sla/lapis.yaml` (L)
4. Implementasi	stack dan konektor dijalankan; uji ketersambungan antarlapis dari stack kosong: 45 dari 46 pemeriksaan lulus; ingest GDELT seminggu; hasil didokumentasikan	`data/uji/uji-sla.json`, `uji-sla-api.json`, `uji-sla-gdelt.json` (TL); `code/src/sdg_gudang/gudang/uji_sla.py` (L)

Alasan rancangan. Pengukuran 21 Oktober mendasari penolakan Spark: Raw 12 sumber 142,5 MB, rebuild penuh 215–228 detik, sedangkan GDELT GKG sejak 2016 berukuran 6,5 TB dengan hanya 0,48–1,32 % baris dari media Indonesia. Unduh dan saring dengan 1, 4, 8, dan 16 utas memberi 5,7, 9,7, 18,1, dan 19,5 MB per detik, sehingga tambahan utas di atas 8 tidak menaikkan laju; batasnya jaringan. Spark membagi kerja CPU, tidak menambah bandwidth di satu mesin, dan menambah JVM 2 GB. Uji pembanding 24 Oktober pada data yang sama menguatkannya: pada window bitemporal atas 1.486.490 observasi, Spark lokal 0,95 s dan Trino 1,77 s, keduanya di bawah 2 s dari job penuh 207 s yang 104 s di antaranya habis di parser Python Bronze dan Silver; pada penyaringan GKG, Python satu inti (91–139 MB zip per detik) tidak kalah dari Spark 8 inti (95 MB zip per detik), dan keduanya 8–24 kali laju unduhan. Ambang SLA ditulis lebih dulu di `lapis.yaml` lalu diuji dari stack kosong: job 207,3 s, 0 uji dbt gagal, p95 Trino terburuk 63,6 ms, jembatan ke paket identik 4 dari 4 dalam 50,5 s, GDELT 14 dari 14 aliran-hari lengkap dengan 8,42 GB zip dalam 726 s (11,6 MB per detik). Satu pemeriksaan gagal, API produksi tanpa kompresi (p95 8,4 s), berasal dari cara uji memanggil API; dengan gzip seperti peramban p95 2,2 s, sedangkan waktu proses di server tetap 0,714–0,751 ms. Ambang tidak diubah, dan kedua cara dicatat.

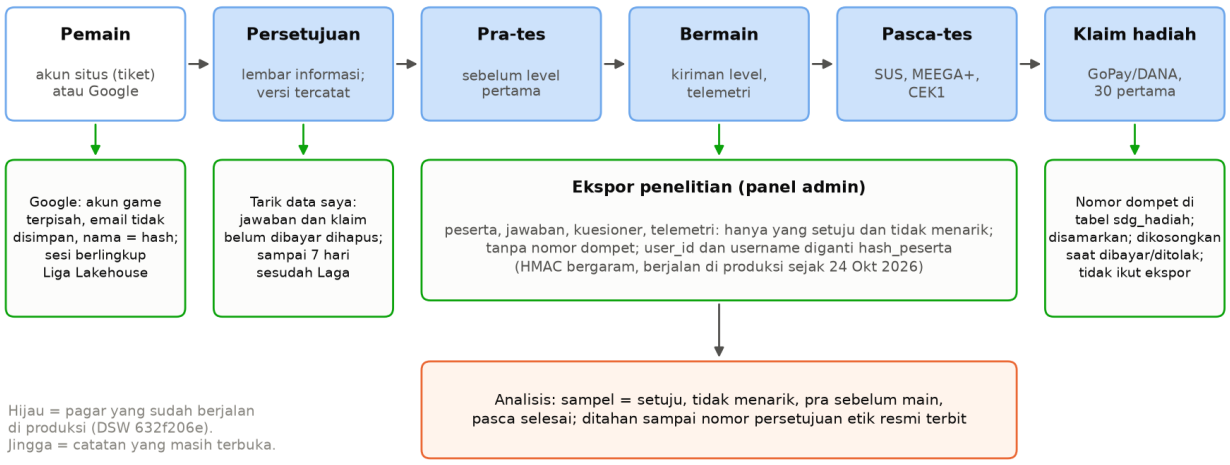
Catatan terbuka. Tidak ada klaster terdistribusi; klaim dibatasi pada volume yang diuji, sekitar 1,5 juta observasi dan 8,42 GB berita per minggu. Uji GDELT baru satu jendela, dan CC-NEWS serta RSS belum punya uji SLA tersendiri.

3.11 Pelindungan data pribadi

J.62PDP00.011.1 Menerapkan Program Kerja Pelindungan Data Pribadi · SKKNI 103/2023 · bukti dari korpus berita dan evaluasi pengguna daring · status: lengkap, satu catatan terbuka

Langkah ini menjawab pertanyaan: data pribadi siapa yang diproses, dengan dasar apa, dan bagaimana dilindungi. Unit ini menuntut program PDP yang benar-benar diterapkan, dan bukti terkuatnya adalah Laga Liga Lakehouse daring, yang sejak 23 Oktober 2026 memproses data peserta sungguhan di server produksi; alur korpus berita menjadi bukti pendukung. Repositori portofolio tidak memuat data pribadi peserta mana pun.

Elemen	Pekerjaan	Bukti
1. Kebijakan PDP	lima prinsip UU 27/2022 pada alur berita; lingkup tujuan evaluasi; inventaris data pribadi per aliran; mekanisme persetujuan, tes, hadiah; DPIA ringkas sembilan risiko	README langkah 11 (T)
2. Kebijakan data terkait PDP	kebijakan simpan berita; masa simpan lima tahun untuk data peserta dan raw berita; peran pemegang garam, pembayar hadiah, dan pemusnah data	`data/serkom/raci.csv` kegiatan 3, 18, 22–24 (T)
3. Prosedur pemrosesan	persetujuan sebelum bermain; penarikan data sampai 7 hari sesudah Laga; verifikasi lima cek oleh admin; pengosongan nomor dompet	modul survei di repositori DSW (L)
4. Pengungkapan kepada pihak lain	ekspor penelitian memakai `hash_peserta` HMAC bergaram, bukan `user_id` atau username; hanya peserta yang setuju masuk berkas analisis; nomor dompet tidak ikut ekspor; hasil hanya agregat	ekspor ber-pseudonim di produksi sejak 24 Oktober 2026, 17 uji (L)
5. Teknologi terkait PDP	akun Google terpisah tanpa email dengan nama ber-hash; sesi berlingkup; tabel hadiah terpisah; pagar kolom konektor berita beserta ujinya	`code/src/sdg_gudang/akuisisi/konektor/berita_umum.py`, `code/tests/unit/test_gudang_konektor_berita.py` (L)



Gambar 9. Alur data peserta Laga. Kotak hijau adalah pagar yang sudah berjalan di produksi; kotak jingga adalah catatan yang masih terbuka.

Alasan rancangan. Lembar persetujuan menjanjikan bahwa username diganti kode hash satu arah sebelum analisis, dan janji ini dijalankan oleh server, bukan bergantung pada kehati-hatian peneliti saat mengolah berkas: ekspor penelitian mengganti `user_id` dan `username` dengan satu kolom `hash_peserta`, yaitu HMAC-SHA256 dengan garam yang hanya ada di environment server, dan ekspor ditolak bila garam belum diset, sehingga tidak ada kunci bawaan di kode. Saat meninjau kode sebelum pemasangan, ditemukan bahwa berkas peserta masih memuat baris akun yang menolak atau menarik persetujuan; baris itu disaring dan jumlahnya hanya terbaca di ringkasan panel admin. Pada alur berita, kolom nama dan kutipan GDELT tidak pernah dipilih, teks penuh RSS dibuang, dan tupel klaim tidak mempunyai bidang nama, dengan dasar UU 28/2014 yang tidak melindungi angka. DPIA ringkas menilai sembilan risiko; risiko tertinggi bukan teknis, yaitu nomor persetujuan etik resmi yang belum terbit, sehingga data peserta belum dianalisis.

Catatan terbuka. Nomor persetujuan etik resmi belum terbit, sedangkan lembar menampilkan nomor sementara; dua pilihan menunggu keputusan penanggung jawab penelitian bersama komite etik: mengganti teks status etik menjadi "sedang diajukan" dan menahan analisis, atau menghentikan sementara pengumpulan survei. Salinan garam di luar server belum dibuat, penyaring nama pada judul RSS belum dipasang, dan surat etik serta lembar persetujuan masih draf.

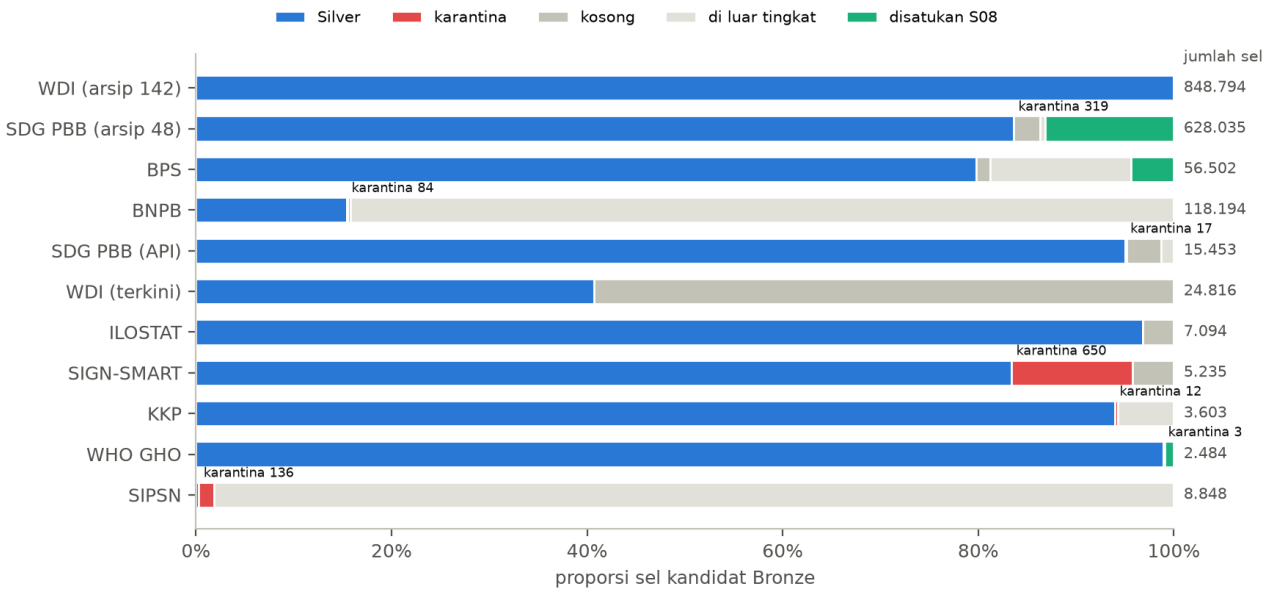
4. Hasil Kerja dan Pemecahan Masalah

Bab ini merangkum hasil yang diperoleh gudang sebagai bukti bahwa artefaknya berjalan dan menghasilkan temuan yang dapat dipertanggungjawabkan: pemetaan Bronze ke Silver, rekonsiliasi multisumber, graf pengetahuan, operasi data mesh, lima insiden beserta perbaikannya, rantai dari gudang ke produk yang berjalan di produksi, serta uji SLA antarlapis dan pembanding Spark. Hasil penelitian lengkap beserta pembahasannya terdapat pada naskah teknis penelitian gudang dan laporan kelima pengujian Tahap II di repositori penelitian Ardika.

Bagian 4.5 mencatat insiden yang terjadi selama pembangunan, karena cara insiden itu ditemukan dan diperbaiki merupakan bukti kompetensi yang sama pentingnya dengan hasil akhirnya.

4.1 Dari Bronze ke Silver

Seluruh 1.487.727 baris Silver dan karantina membawa sha256 berkas Raw yang cocok dengan manifest, dan identitas hitungan sel terpenuhi di semua 54 tabel sumber (`data/gudang/silver_ringkasan.json`).

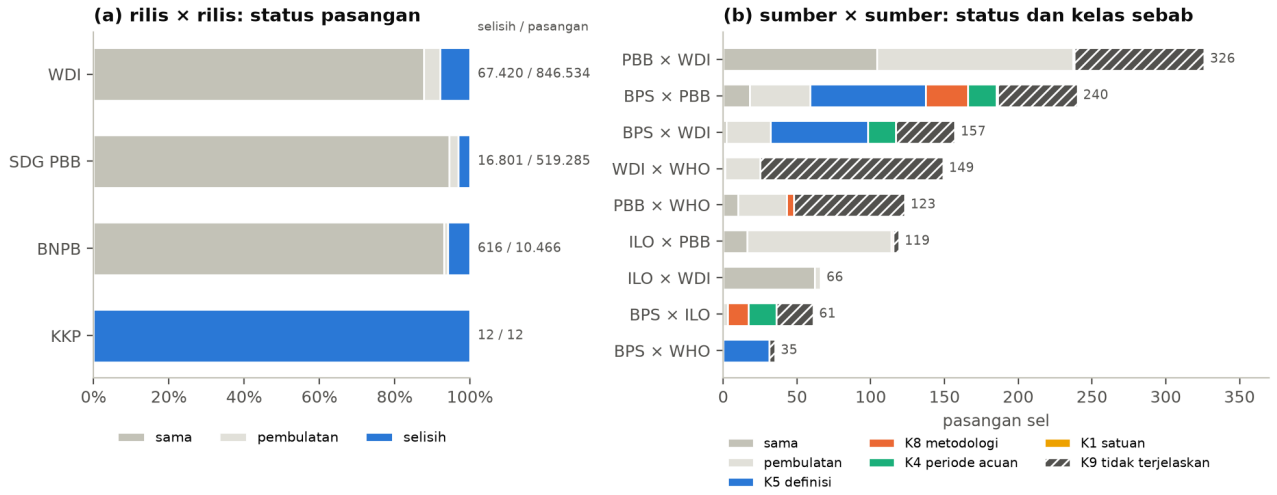


Gambar 10. Proporsi sel kandidat Bronze yang menjadi Silver, karantina, kosong, di luar tingkat, atau disatukan S08, per sumber.

Gambar 10 memperlihatkan dua pola. Sumber internasional bertingkat nasional hampir seluruhnya terpetakan; yang tidak menjadi Silver kebanyakan sel kosong (WDI terkini 59 %) atau kunci ganda bernilai sama pada arsip PBB yang disatukan (13 %). Sumber sektoral didominasi sel tingkat kabupaten/kota (BNPB 84 %, SIPSN 98 %), yang baru menjadi provinsi lewat aturan S09. Karantina terbesar ada di SIGN-SMART (650 sel) karena kode `ID-AC` yang ambigu.

4.2 Rekonsiliasi multisumber

Rekonsiliasi membentuk dua jenis pasangan. Pasangan rilis × rilis dibentuk dalam satu keluarga sumber, sedangkan pasangan sumber × sumber dibentuk antarkeluarga pada konsep yang sama menurut tabel padanan seri.



Gambar 11. (a) Status pasangan rilis × rilis per keluarga. (b) Pasangan sumber × sumber per pasangan keluarga, dirinci menjadi sama, pembulatan, dan kelas sebab selisih.

Tabel 4.1. Ringkasan rekonsiliasi (`data/gudang/m3_rekonsiliasi_ringkasan.json`).

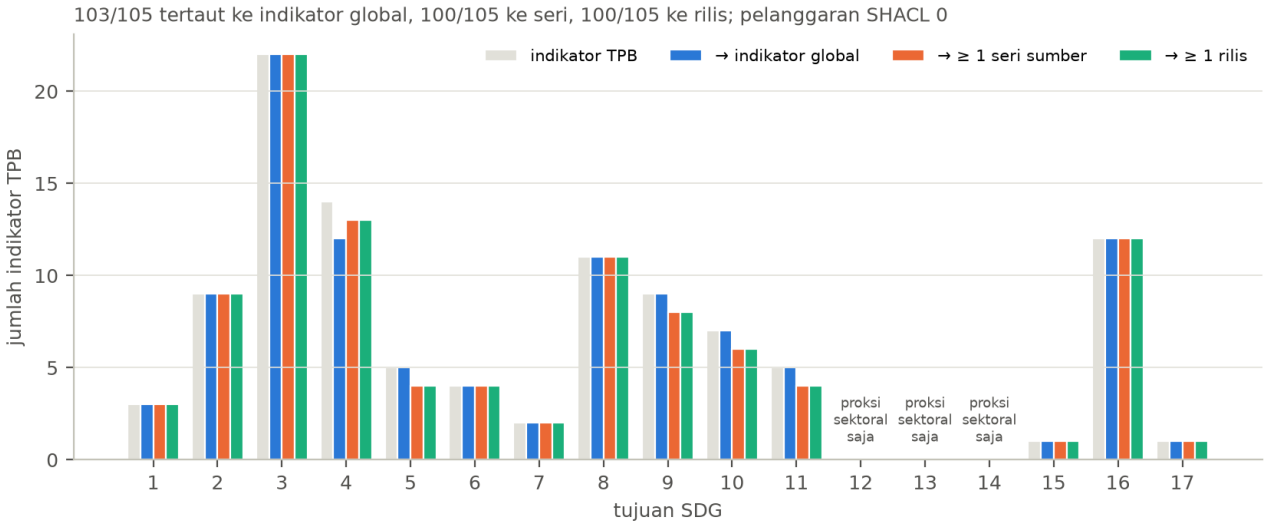
Ukuran	Nilai
Pasangan rilis × rilis	1.376.297; 90,3 % sama, 3,6 % pembulatan, 6,2 % berselisih
Selisih rilis × rilis yang terklasifikasi	84.849 dari 84.849 (terutama vintage, 81.090)
Pasangan sumber × sumber	1.276: 213 sama, 366 pembulatan, 697 selisih
Proporsi selisih sumber × sumber terjelaskan	283/697 = 0,406 (Wilson 95 %: 0,370–0,443)
Kelas sebab selisih sumber × sumber	definisi 175, periode acuan 57, metodologi 49, satuan 2, tidak terjelaskan 414

Hasil ini menunjukkan bahwa perbedaan antarrilis umum dan dapat dijelaskan, sedangkan perbedaan antarsumber jauh lebih sulit dijelaskan. Dari 414 selisih yang tidak terjelaskan, sebagian besar terjadi antara dua sumber internasional dengan selisih relatif kecil. Contohnya angka kematian balita WDI × WHO: keduanya menyalin estimasi UN IGME, tetapi dari ronde yang berbeda. Selisih ini sebenarnya vintage antarkustodian, tetapi aturan beku tidak mempunyai kelas untuknya. Kelas tambahan dicatat sebagai usulan untuk praregistrasi berikutnya dan tidak diterapkan surut, agar angka 0,406 tetap merupakan hasil aturan yang ditetapkan sebelum data dilihat.

Dari empat hipotesis yang ditetapkan sebelum data dibandingkan, satu terbukti (TPT BPS dan ILOSTAT berselisih pada 19 dari 19 tahun) dan tiga tidak terbukti. Hipotesis yang tidak terbukti tetap dilaporkan apa adanya.

4.3 Graf pengetahuan dan klaim angka

Graf pengetahuan TPB-KG berisi 85.734 tripel tanpa pelanggaran SHACL, dan menautkan 103 dari 105 indikator TPB ke indikator global serta 100 ke seri dan rilis (`data/gudang/m5_kg_ringkasan.json`). Tujuan 12, 13, dan 14 hanya terwakili proksi sektoral, karena katalog TPB tingkat provinsi tidak memuat ketiganya. Uji graf pada Tahap II membangun ulang graf dari Gold dan memperoleh sha256 berkas N-Triples yang identik dengan graf M5 (`data/produk/uji-graf.json`).



Gambar 12. Jumlah indikator TPB per tujuan dan berapa di antaranya yang tertaut ke indikator global, ke sedikitnya satu seri sumber, dan ke sedikitnya satu rilis. Sumber: naskah penelitian gudang.

Pada 195 klaim dari Berita Resmi Statistik BPS, pemeriksa yang hanya memakai rilis terkini menyatakan 21 angka resmi BPS tidak cocok. Pemeriksaan satu per satu menunjukkan bahwa 19 di antaranya adalah angka TPT yang kemudian direvisi di tabel BPS dan 2 adalah perbandingan dengan konsep yang tidak setara. Sementara itu, pemeriksa as-of menahan vonis pada 190 klaim karena gudang baru menyimpan satu vintage tabel BPS untuk indikator sasaran. Hal ini menunjukkan bahwa pemeriksaan angka resmi memerlukan riwayat rilis; tanpa riwayat itu, pemeriksa dapat menyalahkan angka yang benar pada hari terbitnya.

4.4 Operasi data mesh pada infrastruktur kecil

Tabel 4.2. Data product pilar pada jalan acuan (`data/gudang/m4_sidik_gold.json`; nilai pilihan as-of 20 Oktober 2026, kelas A dan A-SA).

Data product	Baris	Konsep	Wilayah	Sumber
`dp_sosial_provinsi`	21.228	30	38	1
`dp_sosial_nasional`	3.347	65	1	5
`dp_ekonomi_provinsi`	10.547	16	38	1
`dp_ekonomi_nasional`	6.908	25	1	4
`dp_lingkungan_provinsi`	17.436	31	38	2
`dp_lingkungan_nasional`	1.845	30	1	4

Data product	Baris	Konsep	Wilayah	Sumber
`dp_tatakelola_provinsi`	1.315	6	38	1

Tabel 4.3. Waktu langkah job `gudang_penuh` pada uji SLA 24 Oktober 2026 (`data/uji/uji-sla.json`) dibandingkan dengan dua jalan dari nol pada 21 Oktober (`data/gudang/m4_sidik_gold.json`, jalan C dan D).

Langkah	Uji SLA (24 Okt)	Ambang	Jalan C	Jalan D
Bronze dari Raw	43,8 s	120 s	42,5 s	42,9 s
Silver	60,4 s	120 s	60 s	60 s
Rekonsiliasi	42,9 s	120 s	48,5 s	51,5 s
Kualitas	14,8 s	60 s	15 s	17,8 s
Muat Iceberg	3,8 s	60 s	4,2 s	4,7 s
Kontrak	0,1 s	30 s	0,1 s	0,1 s
dbt build (139 node)	40,7 s	180 s	39,9 s	47,4 s
Job total	**207,3 s**	**600 s**	**215 s**	**228 s**

Keempat jalan memberi sidik Gold yang sama pada 23 tabel. Menambah satu data product pilar cukup dengan satu berkas YAML 26 baris, karena pembangkit kontrak dipakai ulang. Dari 109.289 nilai pilihan, 25,7 % tidak boleh tayang karena berasal dari sumber kelas B, dan penyaringannya terjadi secara mekanis.

4.5 Insiden dan perbaikannya

Lima insiden terjadi selama fase gudang dan graf. Penanganannya mengikuti pola yang sama: penyebab dicari sampai akarnya, perbaikan ditempatkan di aturan atau kode (bukan di data), uji ditambahkan agar kesalahan serupa tertangkap, dan hasil sebelum perbaikan disimpan.

Tabel 4.4. Insiden, akar masalah, dan perbaikan.

No	Insiden	Akar masalah	Perbaikan
1	Trino terbunuh OOM saat membangun `fakta_observasi`	heap JVM bawaan 80 % tidak menyisakan memori native	batas kontainer 6 GB, heap 65 % (commit `520b95c`)
2	Rebuild pertama memberi sidik `nilai_pilihan` berbeda	satu konsep menyatukan seri berbeda ukuran, sehingga tie-breaker seri tidak deterministik	konsep diganti; dua uji ditambahkan: satu seri per keluarga per konsep, tidak ada calon setara (commit `520b95c`)
3	Satu rilis tanpa tanggal rilis terurut sebagai rilis PBB terbaru	aturan pengganti tanggal hanya mengenal tanggal snapshot (20 Okt 2026), padahal registri mencatat batas atas (29 Mar 2019); 3.771 pasangan rilis salah urut dan 3.099 nilai pilihan terdampak	tanggal efektif = tanggal rilis, lalu batas atas, lalu snapshot pertama; uji unit dan dua uji dbt kewajaran tanggal (commit `06cf95e`)
4	Jalan dari nol di Mac gagal pada tahap Bronze SIPSN	modul `lxml` tidak tercantum di berkas kebutuhan; jalan bertahap lolos hanya karena memakai Python sistem	`lxml` dipatok versinya (commit `06cf95e`)
5	Job Dagster gagal setelah uji dbt baru ditambahkan	Dagster membaca manifest dbt dari folder `target/` yang diabaikan git	`make m4-jalan` menjalankan `dbt parse` lebih dulu (commit `06cf95e`)

Insiden 3 memberi pelajaran paling besar. Kesalahan ini tidak tertangkap oleh 137 uji kontrak yang lulus sebelum perbaikan, karena kontrak memeriksa skema, kunci, dan rujukan, bukan kewajaran urutan waktu.

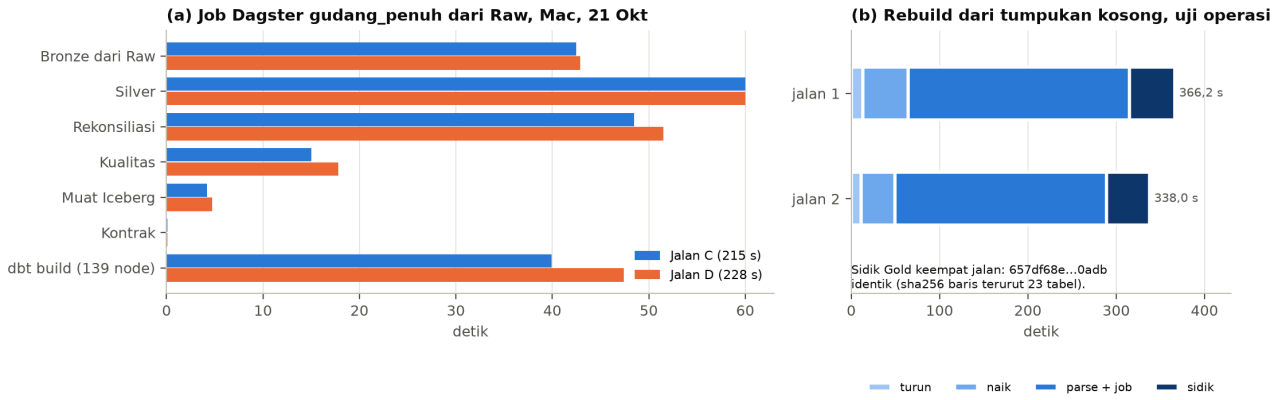
Kesalahan itu baru terlihat ketika data divisualisasikan untuk gambar revisi arsip pada naskah teknis. Setelah diperbaiki, proporsi terjelaskan bergeser dari 0,383 ke 0,406 dan status keempat hipotesis tidak berubah. Pelajaran yang diambil adalah bahwa tanggal rilis perlu diperlakukan sebagai data induk dengan uji tersendiri, dan perubahan ini dilaporkan bersama angka sebelum perbaikan pada naskah teknis, bukan diganti diam-diam.

Insiden 4 dan 5 hanya muncul karena gudang dijalankan ulang dari nol di mesin kedua. Keduanya tidak terlihat pada lingkungan pembangun asli, sehingga pembuktian rebuild di mesin berbeda berfungsi sebagai uji reproduksi, bukan sekadar formalitas.

4.6 Dari gudang ke produk yang berjalan

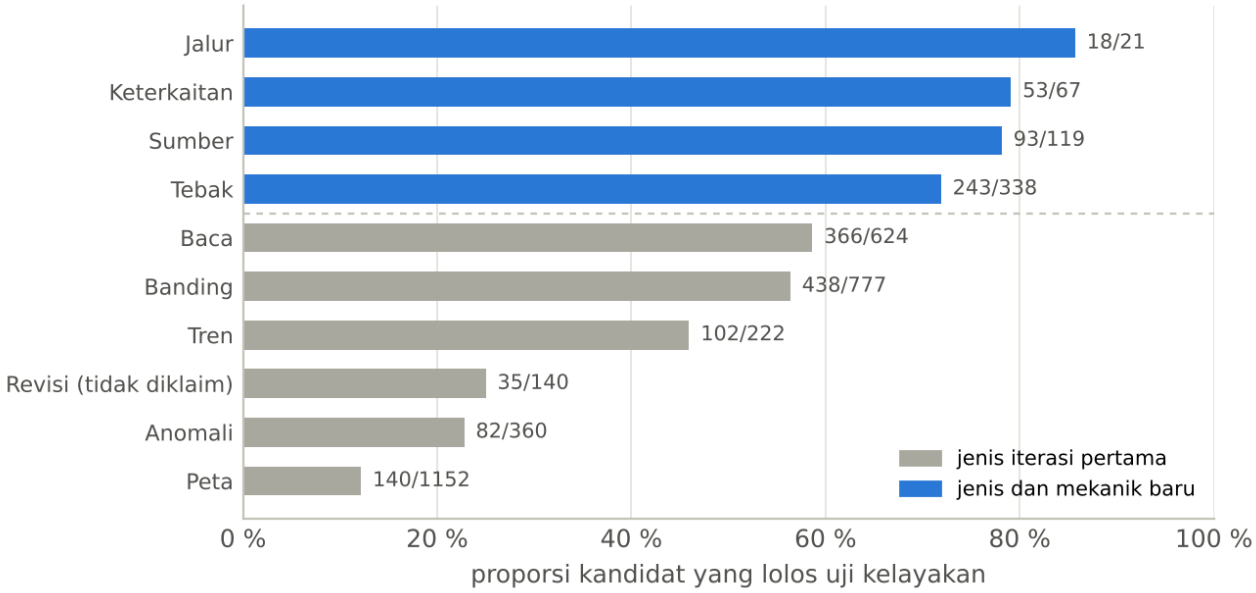
Tahap II menguji apakah gudang dapat menjadi sumber bagi produk yang berjalan di produksi, tidak sebatas tabel analisis. Ada tiga hasil yang relevan untuk portofolio.

Keterulangan rantai penuh. Pada uji operasi, rebuild gudang dari stack kosong diulang dua kali (366 s dan 338 s). Keduanya memberi sidik Gold `657df68e…`, dan keempat berkas ekspor jembatan ke paket level identik byte dengan versi ter-commit. Kompilasi paket versi 4 sebanyak dua kali (16,3 s dan 15,5 s) memberi hash paket `afbcbeef…` yang sama (`data/produk/uji-keterulangan.json`). Rantai Raw, Gold, paket level dengan demikian dapat diulang sampai bita.



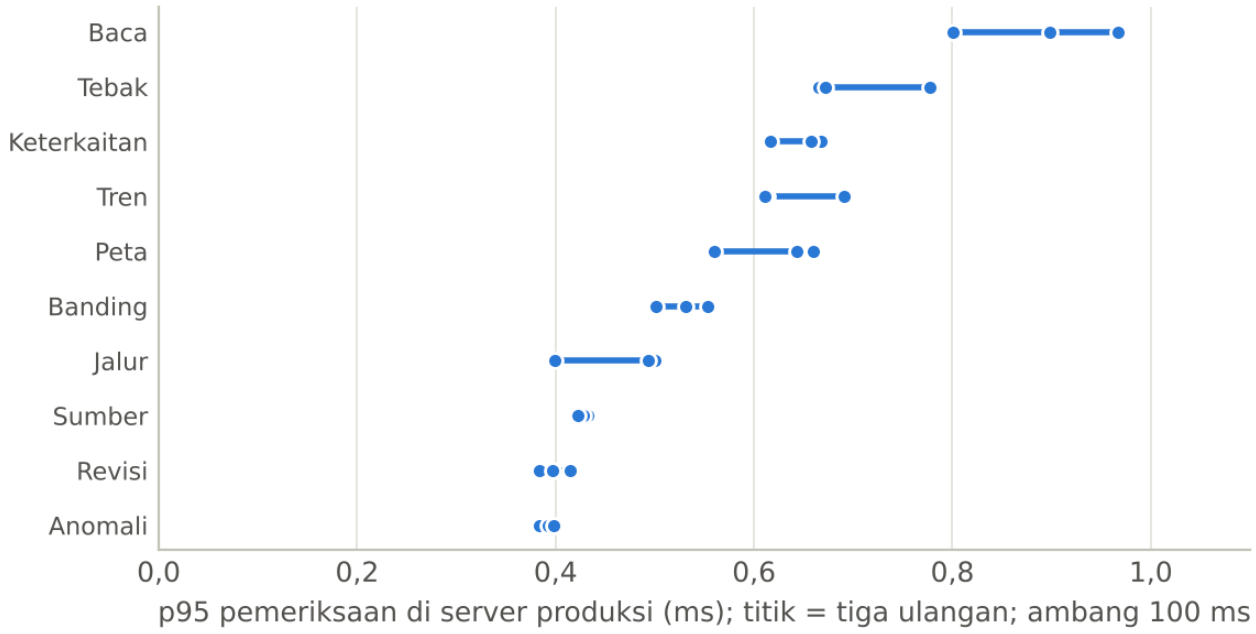
Gambar 13. (a) Waktu langkah job `gudang_penuh` pada jalan C dan D. (b) Dua rebuild uji operasi dari stack kosong, dirinci menjadi menurunkan stack, menaikkan sampai sehat, `dbt parse` dan job, serta menghitung sidik. Keempat jalan memberi sidik Gold yang sama.

Kelayakan paket level. Kompilator membangkitkan 3.820 kandidat level biasa dari tabel tayang, dan 1.570 (41,1 %) lolos uji kelayakan (`data/produk/uji-kompilasi.json`). Uji kelayakan berperan seperti uji kualitas data untuk produk: kandidat yang jawabannya tidak tunggal atau dapat ditebak tanpa membaca data dibuang dengan alasan tercatat. 836 level non-revisi identik dengan paket v3 kecuali label versinya, dan 73 dari 80 Dunia v3 tetap sama.



Gambar 14. Proporsi kandidat level yang lolos uji kelayakan per jenis pada paket evaluasi. Sumber: naskah penelitian Liga Lakehouse.

Operasi di produksi. Pada server Lightsail 4 GB dengan dua worker API, pemeriksaan jawaban untuk 2.000 kiriman per ulangan mencapai p95 0,714–0,751 ms (ambang 100 ms), dan memuat paket menambah 17,6–17,7 MB memori per worker (ambang 150 MB) dalam 0,13–0,14 detik (`data/produk/latensi-produksi-*.json`).



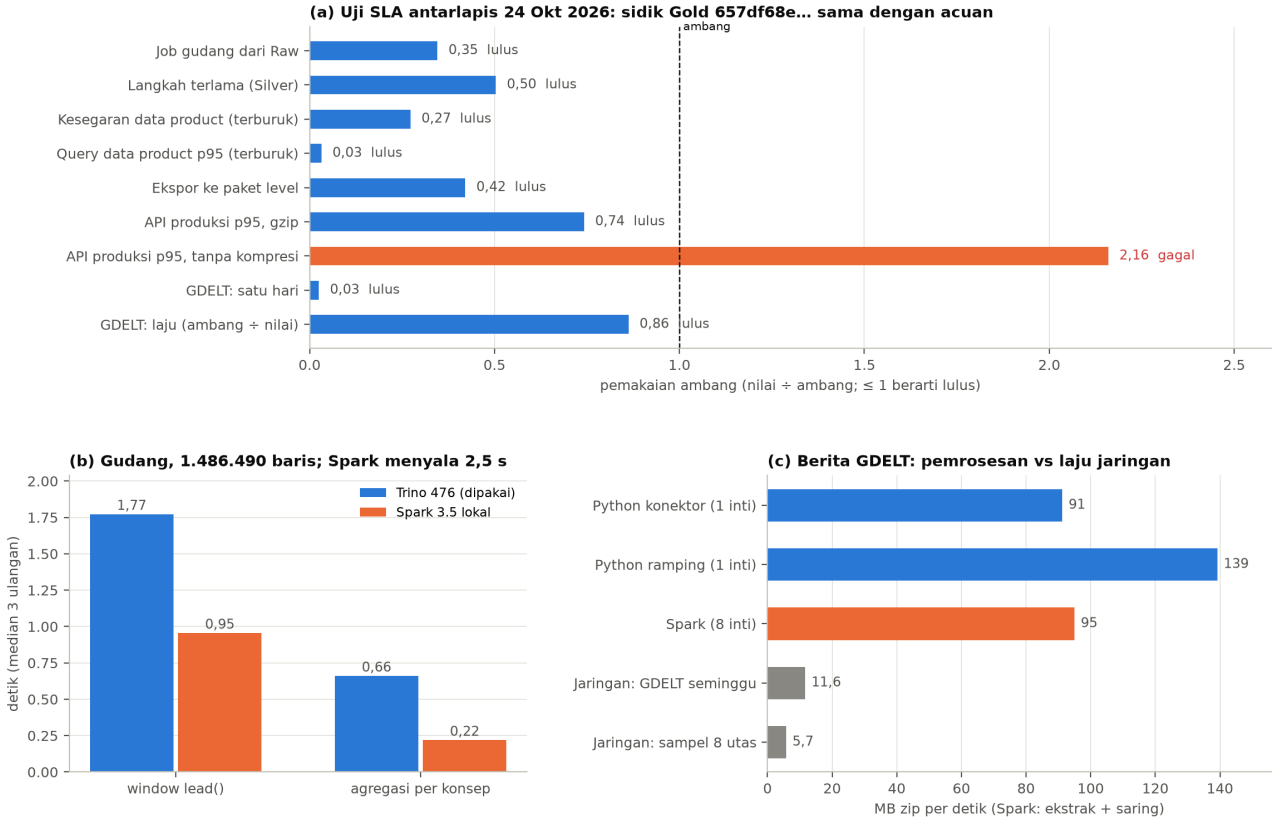
Gambar 15. p95 pemeriksaan jawaban per jenis level di server produksi pada tiga ulangan. Semua jenis berada di bawah 1 ms. Sumber: naskah penelitian Liga Lakehouse.

Perubahan dari rencana uji. Selama Tahap II terjadi empat perubahan dari rencana uji, dan masing-masing dicatat bersama alasan dan dampaknya. Pertama, guardrail Bravais belum memuat alat baru, sehingga jalan

pertama uji keterikatan diarsip dan diulang. Kedua, kartu Jalur membocorkan jawaban level lain, sehingga paket dikompilasi ulang. Ketiga, tabel bantu sempat masuk ke pencarian tabel umum. Keempat, cara menghitung jumlah level Keterkaitan pada penilaian diubah. Penanganannya sama dengan insiden gudang: penyebab dicari, perbaikan ditempatkan di kode, hasil sebelum perbaikan diarsip, dan angka dilaporkan bersama keterangannya.

4.7 Uji SLA antarlapis dan pembanding Spark

Uji ketersambungan antarlapis dijalankan pada 24 Oktober 2026 dengan ambang yang ditetapkan sebelumnya di `config/sla/lapis.yaml`. Gudang dibangun dari stack kosong, lalu setiap perpindahan dari Raw sampai sajian diperiksa terhadap ambangnya. Pada uji yang sama, jalur berita GDELT dijalankan pada jendela tanggal nyata, dan dua beban kerja dibandingkan dengan Spark lokal untuk menjawab pertanyaan apakah Spark diperlukan.



Gambar 16. (a) Pemakaian ambang setiap pemeriksaan SLA; nilai di bawah 1 berarti lulus. (b) Waktu window bitemporal dan agregasi atas Silver pada Trino dan Spark lokal. (c) Laju penyaringan berita GDELT dibandingkan dengan laju jaringan.

Tabel 4.5. Ringkasan uji SLA antarlapis (`data/uji/uji-sla.json`, `uji-sla-api.json`, `uji-sla-gdelt.json`).

Lapis	Hasil	Ambang
Ingest Raw	integritas 1,0 pada 907 berkas; snapshot terakhir berumur 4 hari	1,0; ≤ 7 hari
Proses dari Raw	207,3 s; Silver 60,4 s sebagai langkah terlama; 0 uji dbt gagal	≤ 600 s; ≤ 120 s per langkah; 0

Lapis	Hasil	Ambang
Data product	kesegaran terburuk 109 hari; p95 query terburuk 63,6 ms	≤ 400 hari; ≤ 2.000 ms
Ekspor ke paket level	identik byte 4/4 berkas, 50,5 s	identik; ≤ 120 s
API produksi dari luar	p95 2,2 s dengan gzip; 6,5–8,4 s tanpa kompresi	≤ 3 s
Ingest GDELT 14–20 Okt	14/14 aliran-hari lengkap, 0 gagal, 11,6 MB/s	lengkap; 0; ≥ 10 MB/s
Keterulangan	sidik Gold `657df68e…`	sama dengan acuan

Hasil pembanding dibaca apa adanya (`data/uji/banding-spark.json`). Spark tidak lebih lambat; pada window gudang Spark justru lebih cepat sekitar 0,8 detik. Namun, pada skala 1,49 juta observasi kedua mesin selesai di bawah dua detik, sedangkan waktu job penuh didominasi parser Python Bronze dan Silver (104 dari 207 detik). Pada jalur berita, kapasitas penyaringan Python satu inti sudah 8–24 kali laju jaringan, sehingga menambah inti melalui Spark tidak mempercepat ingest. Oleh karena itu, keputusan tidak memakai Spark tetap dipertahankan. Bila volume tumbuh, langkah yang lebih dulu layak diparalelkan adalah parser Bronze dan Silver.

5. Keterbatasan Bukti dan Tindak Lanjut

Delapan keterbatasan bukti dinyatakan di bab ini agar penilaian didasarkan pada keadaan yang sebenarnya: kepemilikan domain yang masih simulasi, big data tanpa klaster terdistribusi, nomor persetujuan etik yang belum terbit, surat izin yang belum dikirim, repositori metadata versi ringan, cakupan pemeriksaan klaim berita, dua Gold dengan sidik berbeda, dan kode asal yang berada di repositori privat. Bagian 5.2 memuat pekerjaan yang tersisa per langkah sampai penutupan portofolio pada 31 Desember 2026.

5.1 Keterbatasan bukti

1. **Kepemilikan domain masih simulasi.** Keempat domain pilar dipegang oleh asesi sendiri. Sisi teknis federasi sudah terbukti, karena aturan global ditegakkan otomatis tanpa pelanggaran. Namun, sisi organisasinya, yang menurut literatur data mesh justru paling sulit, belum mempunyai bukti. Keterbatasan ini relevan untuk langkah 01–03.
2. **Big data tanpa klaster terdistribusi.** Pemrosesan bervolume besar dilakukan secara streaming dengan Python, dan keputusan tidak memakai Spark didukung uji pembanding: pada skala gudang ini Spark lokal hanya lebih cepat kurang dari satu detik per langkah, sedangkan pada jalur berita batasnya jaringan. Laporan ini tidak mengklaim skalabilitas di atas volume yang diuji, yaitu sekitar 1,5 juta observasi dan 8,42 GB berita per minggu (langkah 10).
3. **Nomor persetujuan etik resmi belum terbit.** Laga sudah mengumpulkan data peserta sejak 23 Oktober 2026, sedangkan lembar persetujuan menampilkan nomor sementara. Pseudonim ekspor sudah berjalan di produksi dan DPIA ringkas sudah ditulis, tetapi data peserta belum boleh dianalisis sampai nomor resmi terbit (langkah 11, risiko R1 di DPIA).
4. **Surat izin dan berkas etik belum dikirim.** Empat surat izin (UNSD, KLH/BPLH, KKP, ANTARA) dan tiga berkas etik masih berupa draf di repositori penelitian, dan folder `bukti/surat/` di portofolio masih kosong sampai surat ditulis ulang tanpa data pribadi. Status tayang basis data SDG PBB, SIPSN, SIGN-SMART, dan KKP ditetapkan pada 22 Oktober 2026 sebagai data publik dengan atribusi wajib.
5. **Repositori metadata versi ringan.** OpenMetadata tidak dipasang karena kebutuhan memorinya, dan digantikan oleh DCAT, dbt docs, serta katalog Iceberg REST (langkah 05).
6. **Pemeriksaan klaim berita baru mencakup dua indikator.** Akurasi ekstraksi (κ antaranotator dan F1) belum diukur karena dua anotator belum ditetapkan.
7. **Ada dua Gold dengan sidik berbeda.** Angka laporan memakai Gold acuan `657df68e…`, yaitu dasar kelima pengujian Tahap II. Gold yang dipakai paket Laga (`1b8c95e3…`) hanya berbeda pada kelas lisensi empat sumber. Perbedaan ini relevan apabila angka laporan dibandingkan dengan layanan produksi (langkah 09).
8. **Kode asal berada di repositori privat.** Repositori penelitian Ardika dan repositori layanan Data Science Workbench bersifat privat. Kode gudang yang dirujuk bukti sudah disalin ke folder `code/` repositori

portofolio dari commit `dcaa55e`, dengan dua penyesuaian untuk publikasi yang dicatat di `code/README.md` (kredensial bawaan stack lokal diganti placeholder, alamat pelacak isu repositori privat dihapus), sehingga dapat dibaca tanpa akses tambahan. Empat berkas uji SLA yang belum ter-commit disalin dari salinan kerja dengan sidiknya dicatat. Kode layanan DSW, yaitu modul Laga, masuk dengan Google, dan ekspor penelitian, tidak disalin dan tersedia untuk ditunjukkan pada saat asesmen.

5.2 Pekerjaan yang tersisa per langkah

Tabel 5.1. Pekerjaan yang tersisa sampai penutupan portofolio (31 Desember 2026).

Langkah	Yang tersisa	Waktu
11 Pelindungan data pribadi	nomor persetujuan etik resmi sebelum analisis Laga; salinan garam di pengelola kata sandi; penyaringan nama pada judul RSS; pemusnahan terjadwal	segera (etik)
01–03 Perencanaan	keputusan pemilik domain; bila kelompok mahasiswa dipilih, menambahkan bukti organisasi nyata (kontrak domain sebagai rubrik proyek, laporan masalah per domain); mencocokkan Perpres 39/2019 dengan teks resmi; menyegarkan inventaris aset	November
04 Data rujukan dan master	mengunduh buku Metadata Indikator TPB Bappenas untuk memastikan kode kematian bayi dan arti tanda; menetapkan ruang nama IRI graf; memodelkan pemekaran sebelum 2012	Desember
05 Metadata	mengurasi 72 satuan lokal; melengkapi metadata DCAT untuk Bronze dan Silver	Desember
06 Media penyimpanan	memeriksa kompatibilitas S3 bucket Lightsail; memperbarui volume setelah unduhan manual BNPB dan Bappenas; menjalankan deduplikasi snapshot BPS	Desember
07–08 Integrasi dan kualitas	kelas sebab vintage antarkustodian pada praregistrasi berikutnya; tabel kode SIGN-SMART dari KLH/BPLH; berkas asli BNPB 2000; log jalan terjadwal dan tren kualitas antarjalan	Desember
09 Gudang data	menguji query time travel Iceberg sebagai bagian pengujian resmi	Desember
10 Big data dan operasi	menjalankan uji SLA secara terjadwal; uji SLA tersendiri untuk CC-NEWS dan RSS	Desember
Portofolio	mengisi FR.APL.02 per elemen; menulis ulang surat tanpa data pribadi ke `bukti/surat/`; memastikan jumlah unit dan format kepada LSP DKS	November

5.3 Penutup

Berdasarkan bukti yang terkumpul sampai 27 Oktober 2026, kesepuluh unit dari SKKNI 268/2020 pada skema Insinyur Data LSP DKS sudah mempunyai berkas bukti per elemen yang lengkap, dan unit kesebelas, PDP, juga lengkap dengan satu catatan terbuka, yaitu nomor persetujuan etik resmi yang belum terbit. Setiap angka di laporan ini dapat ditelusuri ke berkas di `data/`, dan kode yang menghasilkannya dapat dibaca di `code/`.

Bukti terkuat terdapat pada langkah yang berkaitan dengan pembangunan gudang (04, 07, 08, 09). Artefaknya dapat dijalankan ulang dan menghasilkan sidik yang sama sampai ke paket level, dengan perintah yang tercantum pada Lampiran 6.2. Sebaliknya, bukti yang paling bergantung pada keputusan organisasi terdapat pada sisi perencanaan (01–03), yaitu pengisi peran pemilik domain. Oleh karena itu, tindak lanjut yang didahulukan adalah menuntaskan persetujuan etik sebelum data Laga dianalisis, kemudian menetapkan pemilik domain agar bukti organisasi federasi dapat ditambahkan.

6. Lampiran

Lampiran ini merangkum keputusan rancangan beserta alternatif yang dipertimbangkan dan alasannya, mencantumkan perintah untuk membangun ulang bukti dari Raw, dan mendaftar berkas bukti per langkah beserta data dan kode yang menjadi dasarnya.

6.1 Keputusan rancangan dan alasannya

Tabel 6.1. Keputusan rancangan pokok, alternatif yang dipertimbangkan, alasan, dan langkah yang terkait. Setiap keputusan tercatat bertanggal pada dokumen rencana kerja atau catatan rencana uji di repositori penelitian.

Keputusan	Alternatif yang dipertimbangkan	Alasan	Langkah
Model operasional federasi (data mesh) dengan aturan global yang ditegakkan pusat	model terpusat; model tereplikasi	lebih dari sepuluh produsen dengan pengetahuan domain berbeda membuat satu tim pusat menjadi hambatan, sedangkan kode wilayah, indikator, dan satuan harus sama di semua pilar agar level lintas tujuan dapat dibentuk	01, 03
Pemisahan tata kelola data dari tata kelola TI	satu tatanan untuk keduanya	tata kelola data memutuskan kelas tayang, aturan rekonsiliasi, toleransi, dan retensi; tata kelola TI memutuskan ukuran server, cadangan, versi Iceberg dan Trino, serta akses SSH	01, 02
Aturan rekonsiliasi dan ambang kualitas di-commit sebelum data dinilai	menetapkan ambang setelah melihat hasil	hasil yang buruk tidak dapat mengubah ambang; commit `89e0387` mendahului penilaian pertama	02, 08
Pengetahuan domain disimpan di kontrak, metadata, dan uji yang dibangkitkan dari YAML	dokumen panduan yang dibaca pemilik domain	siklus semester membuat pengisi peran domain berganti; aturan yang dapat dieksekusi bertahan lebih lama daripada dokumen	03, 05
Setiap sel Bronze berakhir di tepat satu dari lima tempat, dengan karantina beralasan	membuang baris yang gagal dipetakan	identitas hitungan sel diuji per tabel sehingga tidak ada nilai yang hilang tanpa jejak; kode wilayah ambigu (`ID-AC`) dikarantina, bukan ditebak	07, 08
Raw disimpan selamanya; payload global yang hanya diekstrak disimpan sebagai sha256, ukuran, dan URL	mengunduh ulang bila perlu; menyimpan semua payload utuh	produsen menimpa nilai lama di kanal daring sehingga Raw menjadi satu-satunya bukti angka yang pernah terbit; payload 2,63 GB dapat diunduh ulang dan diverifikasi dari manifest	06

Keputusan	Alternatif yang dipertimbangkan	Alasan	Langkah
Pemrosesan streaming dengan Python, tanpa Spark	Spark untuk arsip WDI dan korpus berita	Silver hanya sekitar 1,5 juta baris; pada window gudang Spark lokal lebih cepat sekitar 0,8 s dari job 207 s, dan pada berita Python satu inti (91–139 MB/s) sudah 8–24 kali laju jaringan (5,7–11,6 MB/s)	10
Ambang SLA per lapis ditulis lebih dulu, lalu diuji dari stack kosong	mengukur lalu menetapkan ambang	45 dari 46 pemeriksaan lulus; kegagalan API tanpa gzip dicatat dan ambangnya tidak diubah	10
Dimensi wilayah tipe 2 dengan versi yang ditutup, bukan dihapus	kode wilayah tunggal terkini	pemekaran 2012 dan 2022 membuat Papua 2021 dan Papua 2023 bukan wilayah yang sama; deret lintas pemekaran ditandai tidak sebanding	04
Resolver menimbulkan galat `KodeAmbigu` bila periode tidak diberikan	memilih kode yang paling mungkin	kode Kemendagri Papua Barat Daya sama dengan Papua Barat pada periode bridging 2023–2024, sehingga tebakan dapat salah	04
Repositori metadata versi ringan (DCAT, dbt docs, katalog Iceberg REST)	OpenMetadata	OpenMetadata memerlukan sekitar 40 GiB RAM dan tidak muat pada node 16 GB; batasan variabel unit membolehkan repositori di alat lain	05
Nilai negatif emisi SIGN-SMART tidak dikoreksi	mengoreksi data agar lolos validitas	emisi bersih kehutanan sah bernilai negatif karena serapan; yang belum membedakannya adalah kerangka validitas, dan perbaikannya dicatat untuk praregistrasi berikutnya	08
Skema bintang bitemporal: waktu rilis untuk query as-of, waktu catat untuk time travel	satu kolom waktu	angka yang benar pada hari terbitnya (TPT 5,28 %) dan nilai terkini (5,23 %) harus sama-sama tersimpan dan dapat dipanggil	09
Nilai pilihan dihitung aturan prioritas tercatat, bukan skor kepercayaan beku	fusi data dengan skor kepercayaan	semua observasi tetap tersimpan dan alasan pilihan tersaji pada setiap baris; sumber yang tidak boleh tayang dikeluarkan sebelum pemilihan	09
Sidik Gold dihitung dari baris terurut melalui Trino	hash berkas Parquet atau snapshot Iceberg	sidik tidak bergantung pada bita Parquet maupun snapshot, sehingga empat jalan dari nol dapat dibandingkan langsung	09
Pseudonim peserta dijalankan server dengan HMAC bergaram, ekspor ditolak bila garam belum diset	pseudonim saat mengolah berkas oleh peneliti	janji lembar persetujuan ditepati oleh kode yang berjalan di produksi, bukan oleh kehati-hatian perorangan; tidak ada kunci bawaan di kode	11
Teks penuh berita dibuang; yang disimpan tupel angka dan cuplikan paling banyak dua kalimat	menyimpan artikel utuh	UU 28/2014 tidak melindungi angka; kolom nama dan kutipan GDELT tidak pernah dipilih, dan tupel klaim tidak mempunyai bidang nama	03, 11

6.2 Perintah untuk verifikasi ulang

Perintah berikut dijalankan dari akar repositori penelitian Ardika di Mac dengan venv Python dan Colima aktif. Salinan kode yang sama tersedia di folder `code/` repositori portofolio (commit `dcaa55e`), dan target `make` yang disebut adalah target Makefile repositori penelitian.

```
# data rujukan dan ujinya (langkah 04)
make m1-referensi
make m1-test

# Bronze dari Raw tanpa jaringan, Silver, rekonsiliasi, kualitas (langkah 07, 08)
make m3-bronze m3-silver m3-rekonsiliasi m3-kualitas

# stack gudang lalu job penuh dari Raw (langkah 09)
make m4-naik
make m4-jalan

# sidik Gold dan lineage (langkah 05, 09)
make m4-sidik
make m4-lineage

# uji SLA antarlapis terhadap config/sla/lapis.yaml (langkah 10)
make m4-uji-sla

# bangun ulang TPB-KG dengan validasi SHACL (uji graf)
make m5-kg
```

Verifikasi singkat tanpa membangun ulang gudang dapat dilakukan dengan `make m1-test` (beberapa detik), lalu membandingkan sidik `657df68e…` pada `data/gudang/m4_sidik_gold.json` dan `data/produk/uji-keterulangan.json` di repositori portofolio, serta membuka halaman Liga Lakehouse di `sd.itera.ac.id` sebagai produk yang berjalan. Di repositori portofolio sendiri, `make periksa` memastikan berkas `data/` masih sama dengan sidik di `data/SIDIK.txt`.

6.3 Daftar berkas bukti, data, dan kode per langkah

Tabel 6.2. Folder bukti, berkas data, dan kode yang menjadi dasarnya. Jalur `bukti/`, `data/`, dan `code/` relatif terhadap akar repositori portofolio.

Langkah	Unit	Berkas data di `data/`	Kode di `code/`
`bukti/01-kebutuhan-data/`	J.62DMS00.001.1	`serkom/inventaris-aset-data.csv`	`config/mesh/`
`bukti/02-rencana-manajemen-data/`	J.62DMS00.002.1	`serkom/raci.csv`, `gudang/m4_sidik_gold.json`, `gudang/m4_lineage.json`, `produk/uji-keterulangan.json`	`config/mesh/`, `tests/unit/test_gudang_kontrak.py`
`bukti/03-arsitektur-data/`	J.62DMS00.003.1	`gudang/m4_sidik_gold.json`, `gudang/m4_lineage.json`, `uji/banding-spark.json`	`config/mesh/`, `src/sdg_gudang/gudang/kontrak.py`
`bukti/04-rujukan-dan-master/`	J.62DMS00.008.1	`gudang/m4_sidik_gold.json`, `gudang/m5_kg_ringkasan.json`	`src/sdg_gudang/referensi.py`, `config/referensi/`, `tests/unit/test_sdg_gudang_referensi.py`
`bukti/05-metadata/`	J.62DMS00.009.1	`gudang/m4_lineage.json`, `gudang/m5_kg_ringkasan.json`, `produk/uji-graf.json`, `produk/uji-keterikatan.json`	`src/sdg_gudang/gudang/kontrak.py`, `kg.py`, `lineage.py`

Langkah	Unit	Berkas data di data/	Kode di code/
bukti/06-penyimpanan/	J.62DMS00.005.1	gudang/volume.json, produk/uji-keterulangan.json, produk/latensi-produksi-*.json	src/sdg_gudang/akuisisi/inti.py, infra/gudang/compose.yml
bukti/07-integrasi/	J.62DMS00.004.1	gudang/silver_ringkasan.json, gudang/m3_rekonsiliasi_ringkasan.json, gudang/m3_kualitas.json, gudang/m4_lineage.json, produk/uji-integrasi.json	src/sdg_gudang/silver/, config/rekonsiliasi/, src/sdg_gudang/gudang/lineage.py
bukti/08-kualitas/	J.62DMS00.012.1	serkom/kualitas-per-sumber.csv, serkom/prioritas-perbaikan.csv, gudang/m3_kualitas.json, gudang/silver_ringkasan.json, produk/uji-integrasi.json	src/sdg_gudang/silver/kualitas.py, tests/unit/test_gudang_silver_inti.py, test_gudang_rekonsiliasi.py
bukti/09-gudang-data/	J.62DMS00.014.1	gudang/m4_sidik_gold.json, produk/sidik-gold.json, produk/uji-kompilasi.json, produk/uji-keterulangan.json	dbt/gudang_sdg/, src/sdg_gudang/gudang/muat.py, orkestrasi.py, sidik.py, infra/gudang/
bukti/10-big-data/	J.62DMS00.007.1	gudang/volume.json, uji/uji-sla.json, uji/uji-sla-api.json, uji/uji-sla-gdelt.json, uji/banding-spark.json, produk/latensi-produksi-*.json	src/sdg_gudang/akuisisi/konektor/, config/sla/lapis.yaml, src/sdg_gudang/gudang/uji_sla.py, eval/serkom/banding_spark.py
bukti/11-data-pribadi/	J.62PDP00.011.1	serkom/raci.csv	src/sdg_gudang/akuisisi/konektor/berita_umum.py, tests/unit/test_gudang_konektor_berita.py; di repositori DSW (privat): modul survei, masuk dengan Google, ekspor penelitian

Peta salinan **data/** ke berkas asalnya ada di **data/asal.tsv**, dan sidik sha256 setiap berkas di **data/SIDIK.txt**; sidik setiap berkas kode di **code/SIDIK.txt**. Isian FR.APL.01 dan asesmen mandiri FR.APL.02 berada di **berkas-asesmen/**, yang tidak ikut dipublikasikan karena memuat data pribadi asesi.

Insinyur Data

Portofolio ini disusun dari proyek gudang indikator SDG multisumber dan Liga Lakehouse Kelompok Keahlian Program Studi Sains Data ITERA. Kode, data, dan bukti per unit dapat diperiksa ulang di repositori sdgs-lakehouse; kode dan data asalnya di repositori penelitian Ardika.

Kontak

(0721) 8030188 · Fakultas Sains
ardika.satria@sd.itera.ac.id
ITERA, Lampung Selatan